

Devoir ETL

Description du devoir

Dans ce devoir, on vous demande d'intégrer vos apprentissages sur l'ETL pour répondre à un besoin d'AdventureWorks. À vous de faire des recherches et trouver le moyen de répondre aux besoins d'AdventureWorks.

Si vous avez des questions, nous discuterons l'ensemble des questions lors des séances de cours.

Il est également important, pour réussir à compléter le devoir, de prendre le temps de **décomposer** les tâches en plusieurs petites tâches simples par exemple en expérimentant avec des petits jeux de données afin d'être en mesure de tester rapidement des choses.

Vous êtes invité(e) à discuter de vos stratégies de réalisation avec vos collègues. Par contre, vous devez remettre votre devoir de façon individuelle.

Sujet:

AdventureWorks vous demande de faire une preuve de concept qui va bâtir sur vos réalisations passées. Cette preuve de concept est basée sur les ventes réalisées **auprès de clients particuliers** d'AdventureWorks.

Vous devez fournir des processus ETL rédigés en SQL pour remplir 2 tables de fait :

fact_sales : La première est une fact transactionnelle qui conserve de l'information granulaire

fact_monthly_sales : La deuxième est une fact agrégée au mois du calendrier réel

Toutes ces facts devront être reliées à une seule dimension de date, dim_date, que vous devez générer avec les informations suivantes :

- a. La valeur de la date en format datetime (ceci vous servira par la suite)
- b. Le mois du calendrier (nom, numéro de 1 à 12)
- c. Le quart du calendrier (Q1, Q2, Q3, Q4)
- d. L'année
- e. La combinaison mois du calendrier – année (2010-1, 2010-2 etc.)
- f. La combinaison quart du calendrier – année (2010-Q1, etc.)
- g. L'année fiscale. Cette dernière débute le premier lundi du mois de mars de chaque année.
- h. La semaine fiscale (on compte la semaine fiscale en fonction de la date de début de l'année fiscale)
- i. La combinaison année fiscale – semaine fiscale (2010-1, 2010-52 ou 53 etc.)

1. Éléments à inclure pour la Fact transactionnelle fact_sales :
 - a. Les informations de la date (lien vers dim_date)
 - b. Les informations du produit (lien vers dim_product)
 - i. dim_product devrait être une table différente de celle créée en classe et contenir les attributs suivants : nom, numéro de produit, couleur, coût standard, prix, style, nom de la sous-catégorie, nom de la catégorie.
 - c. La quantité vendue
 - d. Le montant total
 - e. La tranche d'âge des clients. La table est donc agrégée par jour, par produit, par tranche d'âge. La tranche d'âge doit provenir d'une dimension définie de la façon suivante :
 - i. -25 ans
 - ii. 25 ans à 34 ans
 - iii. 35 ans à 44 ans
 - iv. 45 ans et plus

2. Éléments à inclure pour la fact agrégée (fact_monthly_sales) :
 - a. Les informations de la date (lien vers dim_date)
 - b. Les informations du produit (lien vers dim_product)
 - c. La quantité vendue
 - d. Le nombre de commandes (pas de lignes de commandes!)
 - e. Le montant total

IMPORTANT :

- L'année fiscale d'AventureWorks commence toujours le premier lundi du mois de mars et se termine le dimanche juste avant cette date. Par exemple, l'année fiscale 2012 a commencé le 5 mars 2012 alors que l'année fiscale 2011 avait commencé le 7 mars 2011. Note importante : pour les besoins du devoir vous pouvez émettre l'hypothèse que le premier jour de la semaine configuré dans SQL est un lundi. Autrement dit, c'est comme si on mettait `SET DATEFIRST 1` ; en début de commande.

- La fact agrégée doit être alimentée de façon spéciale puisqu'il est possible que l'on ingère des données alors qu'un mois n'est pas encore « bouclé ». Il faut donc être capable de continuer d'alimenter un mois donné au fur et à mesure que de nouvelles données arrivent.
 - Pour cela, plusieurs options s'offrent à vous, vous pouvez notamment vous référer à la notion de « upserts » à l'aide de la commande MERGE en T-SQL mais d'autres options tout aussi valables s'offrent à vous.
 - Vous pouvez tout à fait choisir de remplir vos deux facts pour les ventes à partir du même objet SQL. En fait, ce serait recommandé.

- La création des objets (tables etc.) doit être faite en dehors du code de procédures enregistrées. On exécutera votre script principal pour générer vos objets qui devront exister avant même que l'on ait importé les données une première fois.

- Vous devez respecter les patterns de noms, créer des tables, écrire scripts lisibles, avec des entêtes etc.
- Les données à importer proviennent uniquement de la BD transactionnelle d'AdventureWorks, sauf pour les dates qui doivent être générées selon un calendrier fixe (par exemple, tous les jours entre le 1^{er} janvier 2010 et le 31 décembre 2020).

Démonstration du bénéfice

Quand on exécute votre script de DDL, la BD TIA_ETL doit être (re)créée, les tables créées, et les données insérées.

