

COMPTE RENDU

BI & Datawarehouse – Projet 1 : Prise en Main de SSIS – Schéma en
Étoile et Premières Transformations ETL
3e année Cybersécurité – École Supérieure d'Informatique et du
Numérique (ESIN)
Collège d'Ingénierie & d'Architecture (CIA)

Étudiant : HATHOUTI Mohammed Taha
JIDAL Ilyas
KABORE Mohammad Sharif Jonathan

Filière : Cybersécurité

Année : 2025/2026

Enseignants : M.RIADSOLH

Date : 27 avril 2026

Table des matières

Introduction	3
1 Partie A — Schéma normalisé vs Star Schema	4
1.1 Requête SQL — Ventes par région	4
1.2 Réponses aux questions	4
1.2.1 Comment sont connectées les fact tables dans le diagramme ?	4
1.2.2 Pourquoi parle-t-on de schéma en flocon (Snowflake) ?	4
2 Partie B — Premiers pas avec SSIS	4
2.1 Installation de SSIS et création du projet	4
2.2 Flat File Connection Manager	5
2.3 OLE DB Connection Manager	7
2.4 Data Flow Task — Extract Sample Currency Data	7
2.4.1 Lookup Currency Key	8
2.4.2 Lookup Date Key	9
2.4.3 Sample OLE DB Destination	10
2.5 Exécution du package	11
2.6 Réponses aux questions	11
2.6.1 Quel type de Connection Manager pour lire un fichier texte délimité ?	11
2.6.2 Quels types de Connection Manager pour lire depuis SQL Server ? .	11
2.6.3 Quelle est la différence entre les deux Lookups ?	11
2.6.4 Combien de lignes sont ajoutées à la première exécution ?	11
2.6.5 Que se passe-t-il si on relance le package ?	11
3 Partie C — Conteneur Foreach Loop	11
3.1 Objectif	11
3.2 Création du package Loop_files	12
3.3 Configuration du Foreach Loop Container	12
3.4 Variable et Mappage	12
3.5 Expression sur le Connection Manager	13
3.6 Exécution	14
3.7 Réponses aux questions	15
3.7.1 Quels changements ont été nécessaires sur le Data Flow ?	15
3.7.2 Quel critère doit satisfaire un fichier pour être traité ?	15
3.7.3 Combien de lignes depuis Currency_VEB.txt ?	15

4	Partie D — Création du Data Warehouse	15
4.1	Objectif	15
4.2	Création de la base DWH	15
4.3	Tables du Data Warehouse	16
4.3.1	Dimension Customers	16
4.3.2	Dimension Products (hiérarchie aplatie)	16
4.3.3	Dimension Date et Fact Table	16
4.4	Réponses aux questions	17
4.4.1	Quelles sont les deux méthodes pour ajouter des clés surrogates ?	17
4.4.2	Qu'est-il arrivé à la hiérarchie des produits ?	17
4.4.3	Quels sont les faits dans la Fact Table ?	17
	Conclusion	18

Introduction

Ce rapport présente les travaux réalisés dans le cadre du Lab 1 du cours de Data Warehousing. L'objectif est de se familiariser avec SQL Server Integration Services (SSIS) et de comprendre les différences entre un schéma normalisé et un Star Schema.

Environnement de travail :

- SQL Server Express 2019 — instance : DESKTOP-EL2CLJ0\SQLEXPRESS
- SQL Server Management Studio (SSMS)
- Visual Studio 2022 + extension SSIS (SQL Server Integration Services)
- Bases de données : AdventureWorks2017 et AdventureWorksDW2017

1 Partie A — Schéma normalisé vs Star Schema

1.1 Requête SQL — Ventes par région

La question demande d’écrire une requête répondant à : *“How many products did we sell per Region?”* en utilisant le schéma normalisé d’AdventureWorks2017.

```
1 USE AdventureWorks2017;
2
3 SELECT
4     st.Name          AS Region,
5     p.Name           AS ProductName,
6     SUM(sd.OrderQty) AS TotalQty
7 FROM Sales.SalesOrderDetail sd
8 JOIN Sales.SalesOrderHeader soh ON sd.SalesOrderID = soh.
   SalesOrderID
9 JOIN Sales.SalesTerritory st ON soh.TerritoryID = st.
   TerritoryID
10 JOIN Production.Product p ON sd.ProductID = p.
   ProductID
11 GROUP BY st.Name, p.Name
12 ORDER BY st.Name, TotalQty DESC;
```

Listing 1 – Requête – Ventes par région sur le schéma normalisé

1.2 Réponses aux questions

1.2.1 Comment sont connectées les fact tables dans le diagramme ?

Les fact tables sont connectées aux dimension tables via des **clés étrangères** (foreign keys). Dans AdventureWorksDW, FactResellerSales est reliée à DimCustomer, DimProduct, DimSalesTerritory et DimDate via leurs clés surrogates.

1.2.2 Pourquoi parle-t-on de schéma en flocon (Snowflake) ?

Les dimensions sont normalisées en plusieurs niveaux hiérarchiques. Par exemple, DimProduct est reliée à DimProductSubcategory, elle-même reliée à DimProductCategory — créant une structure en branches, d’où la forme de flocon. Cela contraste avec le Star Schema où chaque dimension est une table unique aplatie.

2 Partie B — Premiers pas avec SSIS

2.1 Installation de SSIS et création du projet

L’extension SSIS a été installée dans Visual Studio 2022 via le Marketplace Microsoft. Un projet **Integration Services** nommé flatfile_extraction a été créé, avec le package renommé flatfile.dtsx.




FIGURE 1 – Template Integration Services Project disponible après installation




FIGURE 2 – Projet flatfile_extraction créé avec le package flatfile.dtsx

2.2 Flat File Connection Manager

Configuration du gestionnaire de connexions pour `SampleCurrencyData.txt` :

- Nom : `Sample Flat File Source Data`
- Paramètres régionaux : *English (United States)*
- Page de codes : 1252 (ANSI - Latin I)
- Format : Délimité (tabulation)

Colonnes renommées et retypées (onglet Avancé) :

Colonne	Nom	Type original	Type final
Colonne 0	AverageRate	DT_STR	DT_STR
Colonne 1	CurrencyID	DT_STR	DT_WSTR
Colonne 2	CurrencyDate	DT_DATE	DT_DBDATE
Colonne 3	EndOfDayRate	DT_STR	DT_STR

Général
Colonnes
Avancé
Aperçu

Spécifiez les caractères qui délimitent le fichier source :

Séparateur de lignes : {CR}{LF}

Séparateur de colonnes : Tabulation (t)

Aperçu des lignes 1-100 :

Colonne 0	Colonne 1	Colonne 2	Colonne 3
1	USD	7/1/2005 0:00	0.99980004
1	USD	7/2/2005 0:00	1.000900811
1	USD	7/3/2005 0:00	0.99960016
1	USD	7/4/2005 0:00	1
1	USD	7/5/2005 0:00	0.99960016
1	USD	7/6/2005 0:00	1.00050025
1	USD	7/7/2005 0:00	0.99950025
1	USD	7/8/2005 0:00	1.00020004
1	USD	7/9/2005 0:00	0.999200639
1	USD	7/10/2005 0:00	1.00020004

Actualiser Réinitialiser les colonnes

OK Annuler Aide

FIGURE 3 – Aperçu des données dans l'onglet Colonnes

Colonne 0	Divers <table> <tr><td>Name</td><td>CurrencyID</td></tr> <tr><td>ColumnDelimiter</td><td>Tabulation (t)</td></tr> <tr><td>ColumnType</td><td>Délimité</td></tr> <tr><td>InputColumnWid</td><td>0</td></tr> <tr><td>DataPrecision</td><td>0</td></tr> <tr><td>DataScale</td><td>0</td></tr> <tr><td>DataType</td><td>chaîne [DT_STR]</td></tr> <tr><td>OutputColumnW</td><td>50</td></tr> <tr><td>TextQualified</td><td>True</td></tr> </table>	Name	CurrencyID	ColumnDelimiter	Tabulation (t)	ColumnType	Délimité	InputColumnWid	0	DataPrecision	0	DataScale	0	DataType	chaîne [DT_STR]	OutputColumnW	50	TextQualified	True
Name		CurrencyID																	
ColumnDelimiter		Tabulation (t)																	
ColumnType		Délimité																	
InputColumnWid		0																	
DataPrecision	0																		
DataScale	0																		
DataType	chaîne [DT_STR]																		
OutputColumnW	50																		
TextQualified	True																		
Colonne 1																			
Colonne 2																			
Colonne 3																			
	Name																		

FIGURE 4 – Renommage et retypages des colonnes dans l'onglet Avancé

2.3 OLE DB Connection Manager




FIGURE 5 – Connexion OLE DB vers AdventureWorksDW2017 via Windows Authentication

2.4 Data Flow Task — Extract Sample Currency Data

Le Data Flow est composé de 4 composants en séquence :




FIGURE 6 – Data Flow complet : Source → Lookup Currency Key → Lookup Date Key → Destination

2.4.1 Lookup Currency Key

- Mode cache : **Full Cache**
- Mapping : CurrencyID → CurrencyAlternateKey
- Colonne de sortie ajoutée : CurrencyKey

```
1 SELECT * FROM [dbo].[DimCurrency]
2 WHERE [CurrencyAlternateKey]
3 IN ( 'ARS', 'AUD', 'BRL', 'CAD', 'CNY',
4      'DEM', 'EUR', 'FRF', 'GBP', 'JPY',
5      'MXN', 'SAR', 'USD', 'VEB' )
```

Listing 2 – Requête SQL du Lookup Currency Key




FIGURE 7 – Configuration de la connexion du Lookup Currency Key




FIGURE 8 – Mapping CurrencyID → CurrencyAlternateKey, sortie CurrencyKey cochée

2.4.2 Lookup Date Key

- Mode cache : **Partial Cache**
- Source : table [dbo].[DimDate]
- Mapping : CurrencyDate → FullDateAlternateKey
- Colonne de sortie ajoutée : DateKey




FIGURE 9 – Configuration du Lookup Date Key (Partial Cache, table DimDate)




FIGURE 10 – Mapping CurrencyDate → FullDateAlternateKey, sortie DateKey cochée

2.4.3 Sample OLE DB Destination

Gestionnaire de connexions OLE DB :

DESKTOP-EL2CLJO_SQLEXPRESS.AdventureWorksDW2017

Nouveau...

Mode d'accès aux données :

Table ou vue - chargement rapide

Nom de la table ou de la vue :

[dbo].[NewFactCurrencyRate]

Nouveau...

☐ Conserver l'identité ☒ Verrou de table

☐ Conserver les valeurs nulles ☒ Vérifier les contraintes

Lignes par lot :

Taille de validation d'insertion maximale : 2147483647

FIGURE 11 – Sélection de la table NewFactCurrencyRate comme destination




FIGURE 12 – Mappages des colonnes vers la table destination

2.5 Exécution du package




FIGURE 13 – Exécution réussie — 1 097 lignes chargées dans NewFactCurrencyRate

2.6 Réponses aux questions

2.6.1 Quel type de Connection Manager pour lire un fichier texte délimité ?

On choisit le type **FLATFILE** qui permet de configurer le délimiteur, le format et les types de données de chaque colonne.

2.6.2 Quels types de Connection Manager pour lire depuis SQL Server ?

On peut utiliser **OLE DB**, **ADO.NET** ou **ODBC**. OLE DB est le plus performant pour SQL Server.

2.6.3 Quelle est la différence entre les deux Lookups ?

Lookup Currency Key utilise le mode **Full Cache** : toutes les données de référence sont chargées en mémoire avant l'exécution — adapté aux petites tables stables.

Lookup Date Key utilise le mode **Partial Cache** : les données sont chargées à la demande — adapté aux grandes tables où toutes les valeurs ne seront pas nécessairement utilisées.

2.6.4 Combien de lignes sont ajoutées à la première exécution ?

1 097 lignes sont insérées dans NewFactCurrencyRate lors de la première exécution.

2.6.5 Que se passe-t-il si on relance le package ?

Les lignes se **dupliquent** (2 194 lignes après 2 exécutions) car la table ne possède pas de contrainte d'unicité. Il faudrait tronquer la table ou ajouter une vérification avant chaque chargement.

3 Partie C — Conteneur Foreach Loop

3.1 Objectif

L'objectif est de traiter automatiquement les 13 fichiers **Currency_*.txt** en boucle, en réutilisant le Data Flow de la Partie B encapsulé dans un conteneur **Foreach Loop**.

3.2 Création du package Loop_files

Le package `flatfile.dtsx` a été copié en `flatfile 1.dtsx`. Son nom interne a été changé en `Loop_files` avec génération d'un nouvel ID.

3.3 Configuration du Foreach Loop Container

- Nom : `Foreach File in Folder`
- Énumérateur : **Énumérateur Foreach File**
- Dossier : `C:\Users\LENOVO\Downloads\PROJET BI\Sample Data`
- Filtre fichiers : `Currency_*.txt`
- Mode récupération : **Complet** (chemin complet du fichier)




FIGURE 14 – Configuration Collection du Foreach Loop Container

3.4 Variable et Mappage

Une variable `User::varFileName1` de type `String` a été créée et mappée à l'index 0. Elle reçoit dynamiquement le chemin complet de chaque fichier à chaque itération.




FIGURE 15 – Création de la variable `varFileName` dans le scope du package




FIGURE 16 – Mappage de `User::varFileName1` à l'index 0 du Foreach

3.5 Expression sur le Connection Manager

Le Flat File Connection Manager a été converti en connexion de package (non partagée). Une expression a été ajoutée sur la propriété `ConnectionString` :

```
1 @[User::varFileName1]
```

Listing 3 – Expression SSIS pour le `ConnectionString` dynamique

La propriété `DelayValidation` a été mise à **True** pour éviter les erreurs de validation au démarrage (le fichier n'existe pas encore lors de la validation).




FIGURE 17 – Data Flow Task intégré dans le conteneur Foreach File in Folder

3.6 Exécution




FIGURE 18 – Exécution réussie — tous les fichiers `Currency_*.txt` traités

```

SQLQuery1.sql - D:\CLJO\LENOVO (89))*) - X ~vsE7FF.sql - DES...2CLJO\L
USE AdventureWorksDw2017;
SELECT COUNT(*) FROM dbo.NewFactCurrencyRate;
  
```

(Aucun nom de colonne)	
1	15726

FIGURE 19 – Vérification SSMS — 15 726 lignes dans `NewFactCurrencyRate` après traitement des 13 fichiers

3.7 Réponses aux questions

3.7.1 Quels changements ont été nécessaires sur le Data Flow ?

Aucun changement sur le Data Flow lui-même. Les modifications ont porté sur :

1. Création d'une variable `User::varFileName1` de type String
2. Ajout de l'expression `@[User::varFileName1]` sur le `ConnectionString` du Flat File Connection Manager
3. Mise à True de la propriété `DelayValidation`
4. Conversion du Connection Manager de niveau projet en niveau package

3.7.2 Quel critère doit satisfaire un fichier pour être traité ?

Le fichier doit correspondre au pattern `Currency_*.txt` et se trouver dans le dossier `Sample Data` spécifié dans la configuration du Foreach.

3.7.3 Combien de lignes depuis `Currency_VEB.txt` ?

D'après les logs d'exécution SSIS, `Currency_VEB.txt` contient environ **1 000** lignes correspondant aux taux de change de la devise vénézuélienne (VEB).

4 Partie D — Création du Data Warehouse

4.1 Objectif

Créer la base DWH qui servira de cible pour les labs suivants. Elle implémente un **Star Schema** avec des dimensions aplaties et une table de faits.

4.2 Création de la base DWH

```
1 USE master;
2 GO
3
4 CREATE DATABASE DWH
5 ON PRIMARY (
6     NAME          = DWH_data,
7     FILENAME      = 'C:\Program Files\Microsoft SQL Server\
8                     MSSQL17.SQLEXPRESS\MSSQL\DATA\DWH.mdf',
9     SIZE          = 100MB, MAXSIZE = 500MB, FILEGROWTH = 50MB
10 )
11 LOG ON (
12     NAME          = DWH_log,
13     FILENAME      = 'C:\Program Files\Microsoft SQL Server\
14                     MSSQL17.SQLEXPRESS\MSSQL\DATA\DWH.ldf',
15     SIZE          = 50MB, MAXSIZE = 200MB, FILEGROWTH = 25MB
16 );
17 GO
18
19 ALTER DATABASE DWH SET RECOVERY SIMPLE;
```


Listing 4 – Création de la base DWH avec Recovery Simple

4.3 Tables du Data Warehouse

4.3.1 Dimension Customers

```

1 CREATE TABLE dbo.Customers (
2     CustomerDwKey    INT IDENTITY(1,1) PRIMARY KEY,
3     CustomerKey      NVARCHAR(15)      NOT NULL,
4     FullName         NVARCHAR(101)     NULL,
5     EmailAddress     NVARCHAR(50)      NULL,
6     BirthDate        DATE              NULL,
7     MaritalStatus    NCHAR(1)          NULL,
8     Gender           NVARCHAR(1)       NULL,
9     Education        NVARCHAR(40)      NULL,
10    Occupation       NVARCHAR(100)     NULL,
11    City             NVARCHAR(30)      NULL,
12    StateProvince    NVARCHAR(50)      NULL,
13    CountryRegion    NVARCHAR(50)      NULL,
14    ValidFrom        DATE              NULL,
15    ValidTo          DATE              NULL,
16    CurrentFlag      INT               NOT NULL DEFAULT 1
17 );

```

Listing 5 – Table dbo.Customers avec support SCD Type 2

4.3.2 Dimension Products (hiérarchie aplatie)

```

1 CREATE TABLE dbo.Products (
2     ProductDwKey      INT IDENTITY(1,1) PRIMARY KEY,
3     ProductKey        INT              NOT NULL,
4     ProductName       NVARCHAR(50)     NULL,
5     Color             NVARCHAR(15)     NULL,
6     Size              NVARCHAR(50)     NULL,
7     ProductSubcategoryName NVARCHAR(50) NULL,
8     ProductCategoryName NVARCHAR(50)   NULL
9 );

```

Listing 6 – Table dbo.Products – hiérarchie aplatie

4.3.3 Dimension Date et Fact Table

```

1 CREATE TABLE dbo.Date (
2     DateDwKey        INT IDENTITY(1,1) PRIMARY KEY,
3     DateKey          INT              NOT NULL,
4     FullDate         DATE              NULL,
5     MonthNumberName  NVARCHAR(20)     NULL,
6     CalendarQuarter  TINYINT          NULL,

```

```

7      CalendarYear      SMALLINT      NULL
8  );
9
10 CREATE TABLE dbo.FactSales (
11     FactSalesKey      INT IDENTITY(1,1) PRIMARY KEY ,
12     CustomerDwKey      INT      NULL ,
13     ProductKey         INT      NULL ,
14     OrderDateKey       INT      NULL ,
15     OrderQuantity      SMALLINT NULL ,
16     SalesAmount        MONEY    NULL ,
17     UnitPrice          MONEY    NULL ,
18     DiscountAmount     FLOAT    NULL
19 );

```

Listing 7 – Tables dbo.Date et dbo.FactSales

4.4 Réponses aux questions

4.4.1 Quelles sont les deux méthodes pour ajouter des clés surrogates ?

1. **IDENTITY(1,1)** : SQL Server génère automatiquement une valeur entière incrémentée à chaque insertion. Simple à utiliser mais moins flexible.
2. **SEQUENCE** : Objet de base de données indépendant qui génère des valeurs séquentielles. Plus flexible : permet de partager la séquence entre plusieurs tables, de définir l'incrément, etc.

4.4.2 Qu'est-il arrivé à la hiérarchie des produits ?

La hiérarchie a été **aplatie (dénormalisée)** dans une seule table **Products**. Au lieu de trois tables reliées (**DimProduct**, **DimProductSubcategory**, **DimProductCategory**), toutes les informations sont regroupées. **Avantage** : requêtes analytiques plus simples et plus rapides sans jointures supplémentaires.

4.4.3 Quels sont les faits dans la Fact Table ?

Les faits sont des **mesures quantitatives** de l'activité commerciale : **OrderQuantity**, **SalesAmount**, **UnitPrice**, **DiscountAmount**.

Conclusion

Ce lab nous a permis de maîtriser les fondamentaux du Data Warehousing avec SSIS :

- **Schéma normalisé vs Star Schema** : compréhension des limitations du schéma normalisé pour le BI et l'avantage du schéma en étoile
- **Flat File Connection Manager** : configuration des types de données, du délimiteur et des colonnes pour l'extraction depuis un fichier texte
- **Data Flow ETL** : création d'un pipeline complet Flat File → Lookup Currency Key → Lookup Date Key → OLE DB Destination (1 097 lignes)
- **Foreach Loop Container** : traitement automatique de 13 fichiers `Currency_*.txt` en boucle (15 726 lignes au total)
- **Création du Data Warehouse** : mise en place d'un schéma en étoile avec dimensions aplaties (`Customers`, `Products`, `Date`) et table de faits (`FactSales`)
- **Concepts clés** : clés surrogates (`IDENTITY`, `SEQUENCE`), Recovery Model Simple, dénormalisation des dimensions

Ces acquis constituent la base nécessaire pour le **Lab 2** qui portera sur le chargement des données dans le Data Warehouse et la gestion des *Slowly Changing Dimensions* (SCD Type 1 et Type 2).