

COMPTE RENDU

BI & Datawarehouse – Importation et intégration de fichiers Excel sur
Talend Open Studio
Rappel (Requêtes Décisionnelles)
3e année Cybersécurité – École Supérieure d'Informatique et du
Numérique (ESIN)
Collège d'Ingénierie & d'Architecture (CIA)

Étudiant : HATHOUTI Mohammed Taha
Filière : Cybersécurité
Année : 2025/2026
Enseignants : M.RIADSOLH
Date : 6 avril 2026

Table des matières

1	Objectif	2
2	Problématique et données	2
3	Architecture du Job ETL	2
3.1	Vue d'ensemble	2
4	Configuration des composants	3
4.1	Sources d'entrée	3
4.1.1	tFileInputDelimited – Product	3
4.1.2	tFileInputExcel – Join_Lookup	3
4.2	Composant de transformation – tMap_1	3
4.2.1	Configuration de la jointure	3
4.2.2	Mapping de la sortie product_out	4
4.2.3	Expression StringHandling – remplacement du tiret bas	4
4.2.4	Expression de catégorisation	5
4.2.5	Mapping de la sortie rejected	5
4.3	Composant de filtrage – tFilterRow_1	5
5	Résultats d'exécution	6
5.1	Fichier Product_Out	6
5.2	Fichier Product_Out_Good	6
5.3	Fichier Reject_Bad	7
5.4	Fichier Reject	7
6	Analyse et conclusion	8

1 Objectif

L'objectif de ce TP est d'importer plusieurs fichiers Excel sur Talend Open Studio, de les combiner en effectuant des opérations de jointure et de transformation afin d'obtenir en sortie les fichiers souhaités.

2 Problématique et données

Nous disposons de deux tables dans deux fichiers Excel distincts :

- **Product_input** : contient les champs `Product_id`, `Product_name` et `Sales_Rating`. Ce fichier renseigne sur le classement des ventes des produits.
- **Join_lookup** : contient `Product_id` et `Total_expenditure`. Ce fichier renseigne sur le coût d'investissement de chaque produit.

L'objectif est de croiser ces deux sources afin d'obtenir, pour chaque produit vendu, son coût d'investissement associé, ainsi qu'une classification Good/Bad basée sur le classement des ventes.

3 Architecture du Job ETL

3.1 Vue d'ensemble

Le job ETL réalisé suit le pipeline suivant :

```
Product (tFileInputDelimited)
  ↓ product (Main)
tMap_1 ← Join_Lookup (tFileInputExcel) via lookup
  ↓ product_out (Main order :1)
Product_Out (tFileOutputDelimited)
  ↓ row1 (Main)
tFilterRow_1
  ↓ product_out_good (Filtre order :1) → Product_Out_Good
  --> product_out_bad (Reject order :2) → Reject_Bad
tMap_1 ↓ rejected (Main order :2) → Reject
```

Le job produit ainsi quatre fichiers de sortie :

- **Product_Out** : tous les produits ayant une correspondance dans la table lookup, avec la colonne `Categorie` calculée.
- **Product_Out_Good** : produits filtrés avec `Categorie = "Good"` (`Sales_Rating > 7`).
- **Reject_Bad** : produits écartés par le filtre, c'est-à-dire ceux avec `Categorie = "Bad"`.
- **Reject** : produits n'ayant aucune correspondance dans la table lookup (rejet de la jointure interne).




FIGURE 1 – Vue complète du Job ETL dans Talend Open Studio

4 Configuration des composants

4.1 Sources d'entrée

4.1.1 tFileInputDelimited – Product

Le composant `tFileInputDelimited_1` lit le fichier `Product_input.csv`. Le schéma est importé depuis les Métadonnées et contient trois colonnes :

Colonne	Type	Length	Nullable
Product_id	Integer	4	✓
Product_name	String	13	✓
Sales_Rating	Integer	2	✓

4.1.2 tFileInputExcel – Join_Lookup

Le composant `tFileInputExcel_1` lit le fichier `Join_Lookup.xlsx` importé depuis les Métadonnées. Il contient deux colonnes : `Product_id` (Integer, 4) et `Total_expenditure` (Integer, 4). Ce composant est connecté au `tMap` en tant que flux *Lookup*.

4.2 Composant de transformation – tMap_1

Le composant central du job est le `tMap_1`, qui réalise la jointure et les transformations sur les champs.

4.2.1 Configuration de la jointure

La jointure entre les deux sources est configurée comme suit dans le `tMap` :

- **Join Model** : *Inner Join* – seuls les produits ayant une correspondance dans la table lookup sont transmis vers la sortie principale `product_out`.
- **Match Model** : *Correspondance unique*.
- **Clé de jointure** : `product.Product_id` → `lookup.Product_id`.
- **Catch lookup inner join reject** : `true` – les produits sans correspondance sont redirigés vers la sortie `rejected`.




FIGURE 2 – Configuration du tMap.1 : jointure, mappings et schémas

4.2.2 Mapping de la sortie product_out

Expression	Colonne de sortie
product.Product_id	Product_id
StringHandling.EREPLACE(product.Product_name, "_", " ")	Product_name
product.Sales_Rating	Sales_Rating
lookup.Total_expenditure	Total_expenditure
product.Sales_Rating > 7 ? "Good" : "Bad"	Categorie

4.2.3 Expression StringHandling – remplacement du tiret bas

Pour remplacer le caractère _ par un espace dans le champ Product_name, la fonction StringHandling.EREPLACE est utilisée dans le constructeur d'expression :

```
1 StringHandling.EREPLACE(product.Product_name, "_", " ")
```

Listing 1 – Expression de remplacement dans tMap




FIGURE 3 – Constructeur d'expression – StringHandling.EREPLACE

4.2.4 Expression de catégorisation

Pour classer chaque produit selon son classement de ventes, une expression ternaire Java est utilisée sur la colonne **Categorie** :

```
1 product.Sales_Rating >7 ? "Good" : "Bad"
```

Listing 2 – Expression de catégorisation Good/Bad




FIGURE 4 – Constructeur d'expression – catégorisation Good/Bad

4.2.5 Mapping de la sortie rejected

Les produits sans correspondance dans la table lookup sont envoyés vers la sortie **rejected** avec les colonnes suivantes :

Expression	Colonne de sortie
product.Product_id	Product_id
product.Product_name	Product_name
product.Sales_Rating	Sales_Rating

4.3 Composant de filtrage – tFilterRow_1

Le composant **tFilterRow_1** est connecté en aval de **Product_Out** et filtre les lignes selon la valeur de la colonne **Categorie**.




FIGURE 5 – Configuration du tFilterRow_1 – filtre sur Categorie = "Good"

Colonne d'entrée	Fonction	Opérateur	Valeur
Categorie	Vide	Vaut	"Good"

Les lignes vérifiant la condition sont envoyées vers `Product_Out_Good` (sortie filtre), et les lignes ne vérifiant pas la condition sont envoyées vers `Reject_Bad` (sortie rejet).

5 Résultats d'exécution

5.1 Fichier Product_Out

Ce fichier contient les 5 produits ayant une correspondance dans la table `Join_Lookup`, avec la colonne `Categorie` calculée :

	A	B	C	D	E	
1	4356	Accessories	10	3456	Good	
2	7896	Vehicles	9	7894	Good	
3	1035	Medicines	7	8976	Bad	
4	1056	Dairy product	8	5432	Good	
5	1058	Clothes	7	1314	Bad	
6						

FIGURE 6 – Contenu du fichier `Product_Out.csv`

Product_id	Product_name	Sales_Rating	Total_expenditure	Categorie
4356	Accessories	10	3456	Good
7896	Vehicles	9	7894	Good
1035	Medicines	7	8976	Bad
1056	Dairy product	8	5432	Good
1058	Clothes	7	1314	Bad

Remarque : le tiret bas (-) a bien été remplacé par un espace dans `Dairy_product` → `Dairy product`.

5.2 Fichier Product_Out_Good

Ce fichier contient uniquement les produits ayant un `Sales_Rating` supérieur à 7 (catégorie Good) :

	A	B	C	D	E	
1	4356	Accessories	10	3456	Good	
2	7896	Vehicles	9	7894	Good	
3	1056	Dairy product	8	5432	Good	
4						
5						
6						

FIGURE 7 – Contenu du fichier `Product_Out_Good.csv`

Product_id	Product_name	Sales_Rating	Total_expenditure	Categorie
4356	Accessories	10	3456	Good
7896	Vehicles	9	7894	Good
1056	Dairy product	8	5432	Good

5.3 Fichier Reject_Bad

Ce fichier contient les produits écartés par le filtre ($\text{Sales_Rating} \leq 7$, catégorie Bad), avec la raison de rejet dans la dernière colonne :

	A	B	C	D	E	F
1	1035	Medicines	7	8976	Bad	Categorie.compareTo("Good") == 0 failed
2	1058	Clothes	7	1314	Bad	Categorie.compareTo("Good") == 0 failed
3						
4						
5						
6						

FIGURE 8 – Contenu du fichier Reject_Bad.csv

Product_id	Product_name	SR	Total_exp	Cat.	Raison
1035	Medicines	7	8976	Bad	Categorie.compareTo("Good") == 0 failed
1058	Clothes	7	1314	Bad	Categorie.compareTo("Good") == 0 failed

5.4 Fichier Reject

Ce fichier contient le produit n'ayant aucune correspondance dans la table Join_Lookup (rejet de la jointure interne) :

	A	B	C	D
1	106	Foot_Wear	6	
2				
3				
4				
5				
6				

FIGURE 9 – Contenu du fichier Reject.csv

Product_id	Product_name	Sales_Rating
106	Foot_Wear	6

Le produit *Foot_Wear* (id 106) ne figure pas dans la table *Join_Lookup*, il est donc rejeté par l'inner join et redirigé vers ce fichier.

6 Analyse et conclusion

Ce TP a permis de mettre en œuvre un pipeline ETL complet sous Talend Open Studio, en couvrant les étapes suivantes :

- **Extraction** : lecture de deux sources hétérogènes (fichier CSV délimité et fichier Excel) via les composants `tFileInputDelimited` et `tFileInputExcel`, avec gestion des schémas depuis les Métadonnées.
- **Transformation** : utilisation du composant `tMap` pour réaliser une jointure interne sur `Product_id`, appliquer une transformation textuelle avec `StringHandling.EREPLACE`, et calculer une colonne dérivée `Categorie` via une expression ternaire Java.
- **Filtrage** : le composant `tFilterRow` a permis de séparer les produits `Good` (`Sales_Rating > 7`) des produits `Bad`, générant deux sorties distinctes.
- **Chargement** : quatre fichiers de sortie ont été produits, couvrant l'ensemble des cas : lignes jointes, lignes filtrées positivement, lignes rejetées par le filtre, et lignes rejetées par la jointure.

Les résultats obtenus sont cohérents avec les données source : 5 produits sur 6 ont une correspondance dans la table lookup, et parmi eux 3 sont classés `Good` et 2 `Bad`. Le produit `Foot_Wear` (id 106) est correctement isolé dans le fichier de rejet de jointure.