Importer des fichiers Excel sur Talend open studio

1- Objectif

L'objectif de ce TP est de pouvoir importer plusieurs fichiers Excel sur Talend, de combiner ses fichiers en effectuant des opérations afin d'avoir en sortie le fichier souhaité.

2- Problématique

Nous avons deux tables dans deux fichiers Excel séparés. La première table contient le classement des produits les mieux vendus d'une entreprise et la deuxième table contient le cout d'investissement de chaque produit. On veut connaitre le cout d'investissement avec le classement des produits les plus vendus.

3- Données

Pour les données nous disposons de deux tables :

- Product_input : contient les champs id_product , Product_name, Sales_rating renseigne sur le classement des ventes des produits.
- Join_lookup: contient id_product et total_expenditure renseigne sur le cout d'investissement de chaque produit.

4- Démarche

Créer un nouveau job dans le **workspace**, en appuyant sur **jobs** avec le bouton droit de la souris :

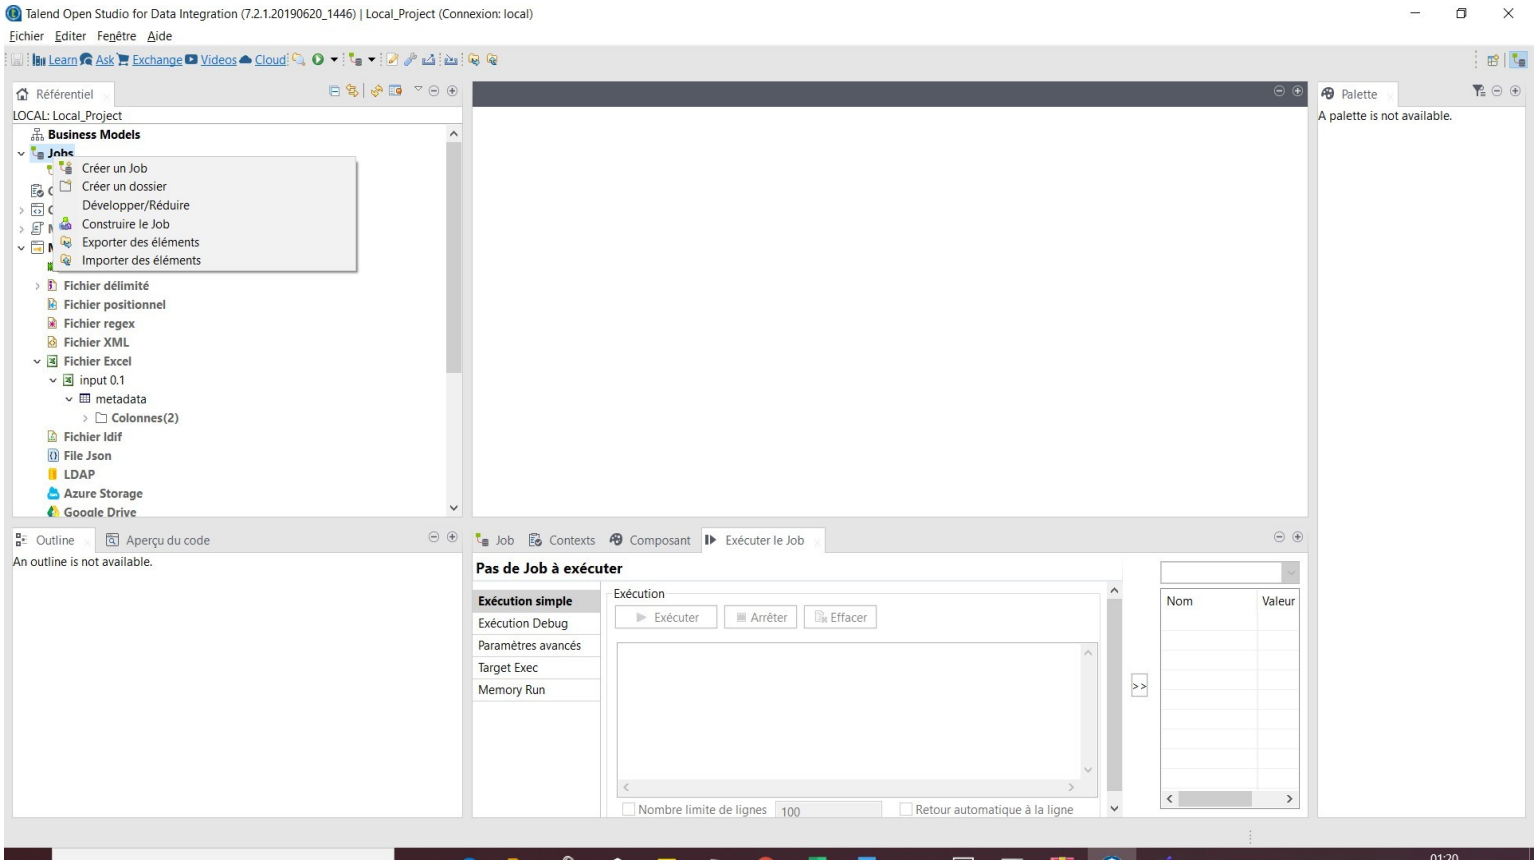

Après la création du job, ajouter le fichier source en input, pour cela chercher dans la palette **'tfileinputdelimeted'** et glisser le vers l'éditeur.

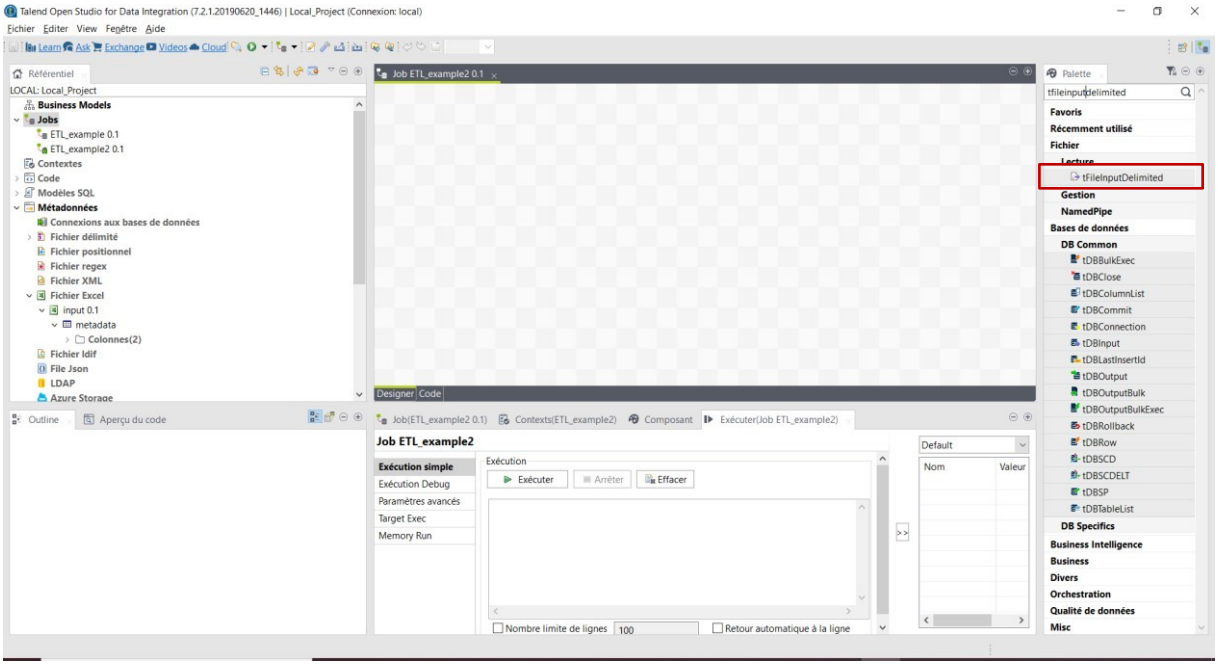

Appuyer sur l'icône de **'tfileinpudelimited'**, et préciser le chemin du fichier qu'on veut importer et préciser que la première colonne contient l'en-tête

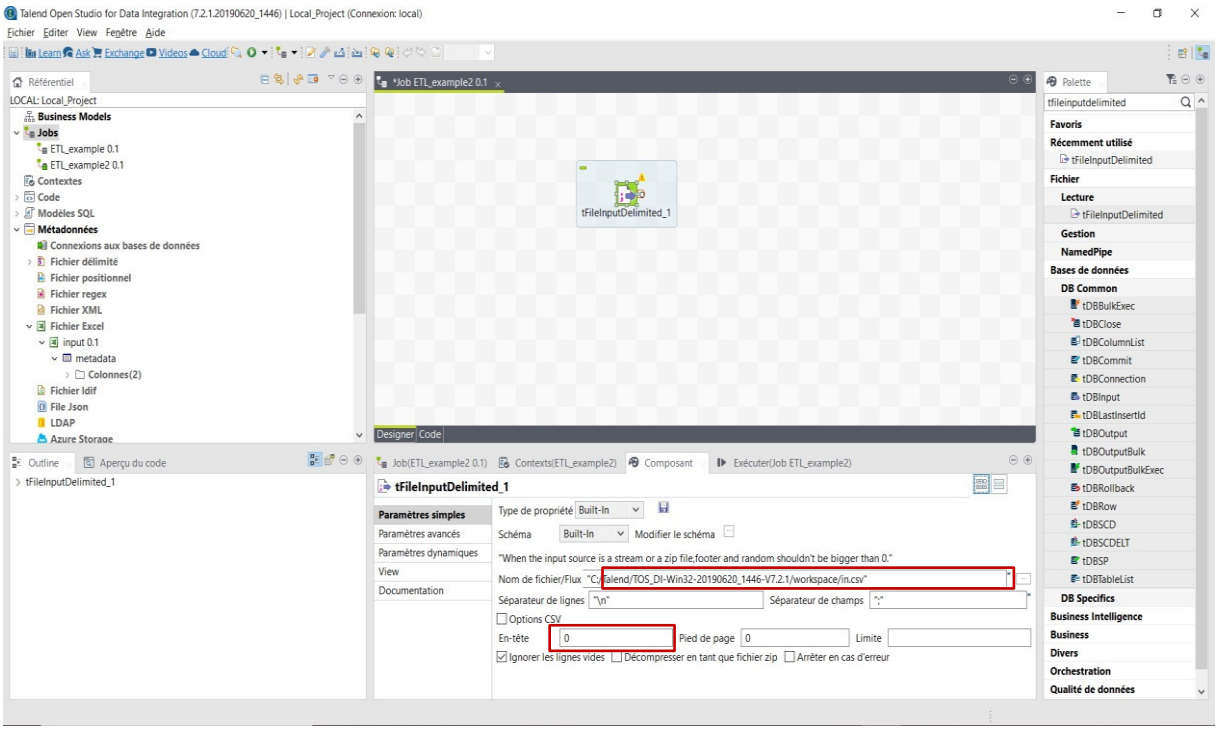

Pour le **Schéma** (Structure), on a deux alternatives soit de rentrer manuellement la structure de la table (colonne par colonne) ou d'importer la structure à partir de **Metadata**. Pour cela, créer un nouveau fichier délimité dans **Metadata**.

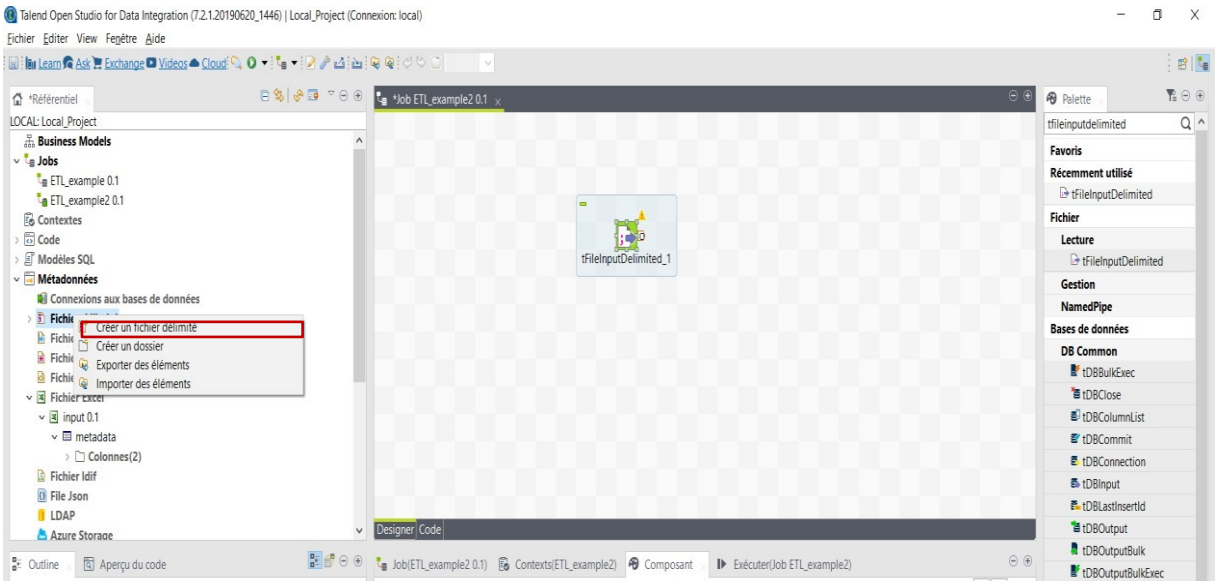

Ensuite renseigner le nom du fichier et le chemin

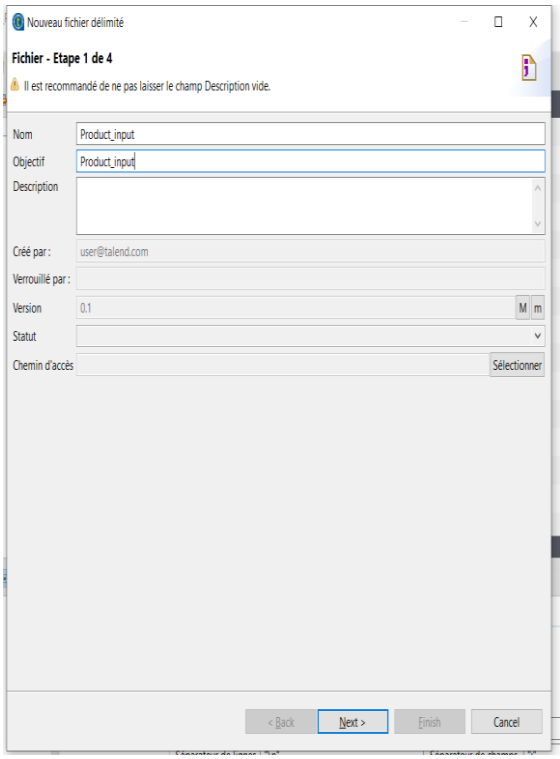

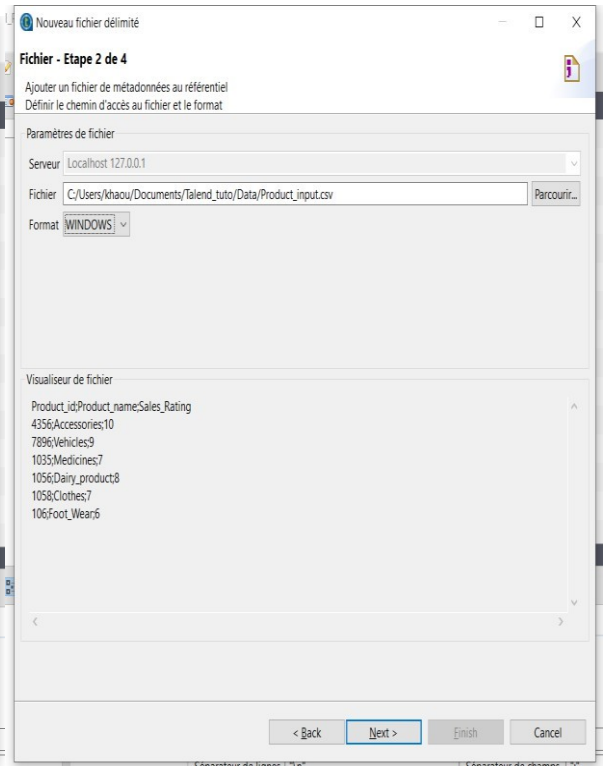

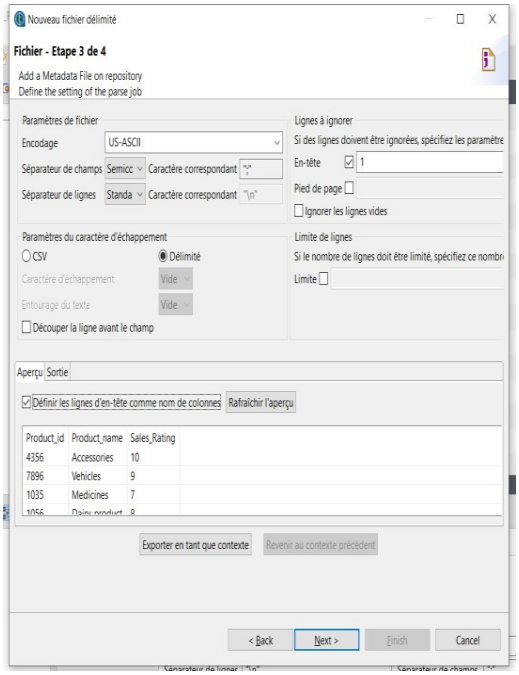

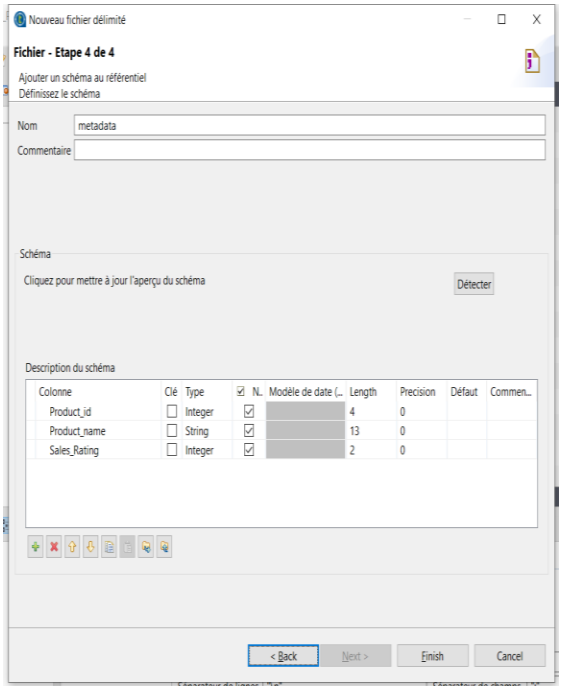

Après avoir importé le fichier dans metadata, revenir à l'icone et changer la valeur de **schéma** de *Built-in* à *Réferentiel* et parcourir Metadata pour choisir la structure du fichier Product_input.

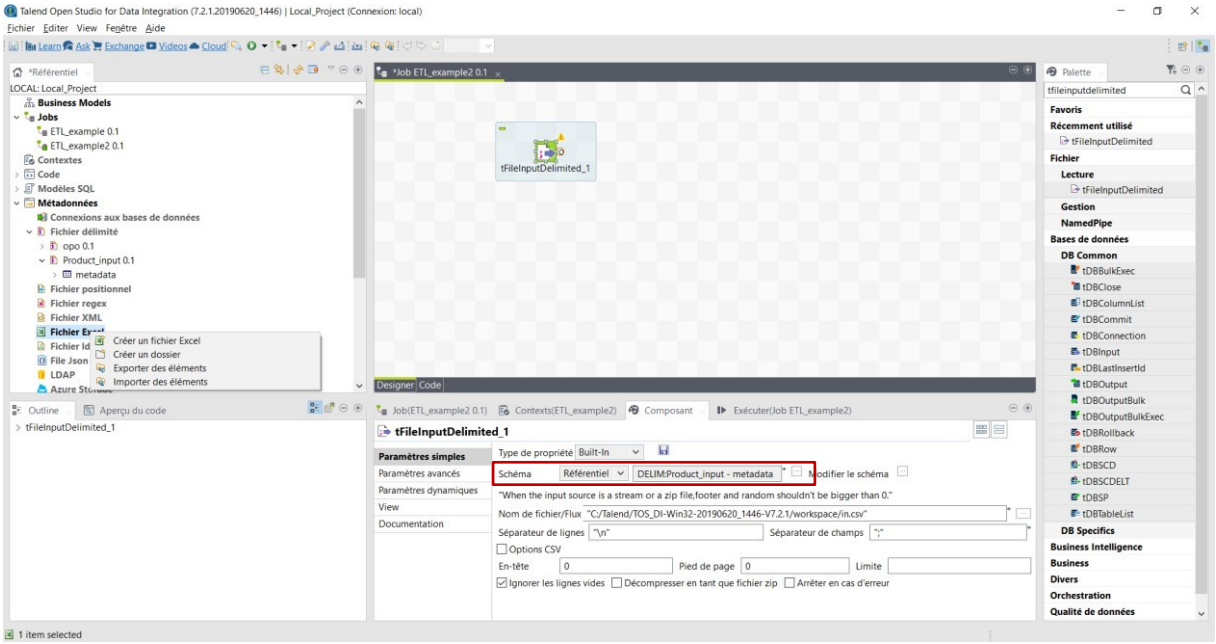

De même, créer un deuxième fichier Excel dans **Metadata**, importer le fichier Join_Lookup.xlsx.

Ensuite il suffit de le glisser dans l'éditeur sans passer par la palette, et on précise que c'est un input file.

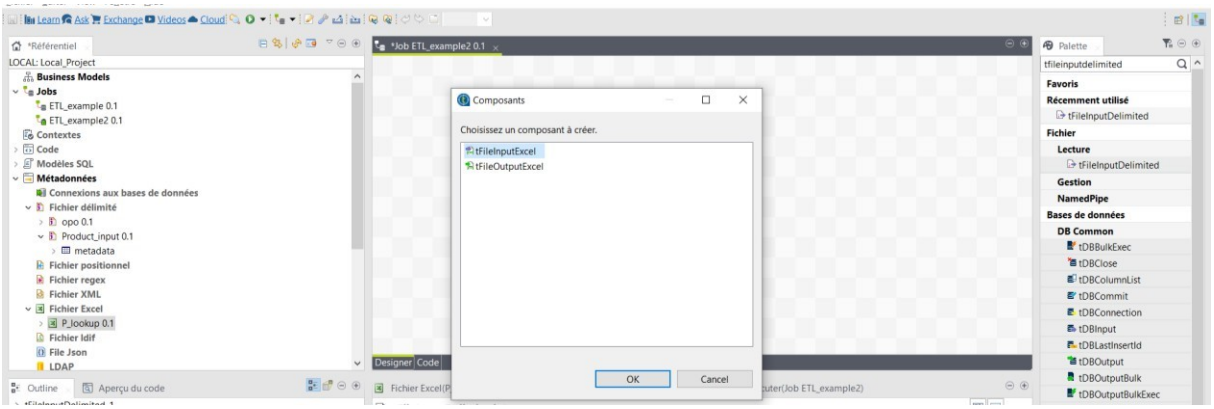

Depuis la palette ajouter **tmap** pour pouvoir agréger les deux fichiers

Connecter les deux fichiers au même **tmap**, avec le bouton droit de la souris appuyer sur le fichier, sélectionner **row** ensuite **main**, et placer la flêche sur tmap

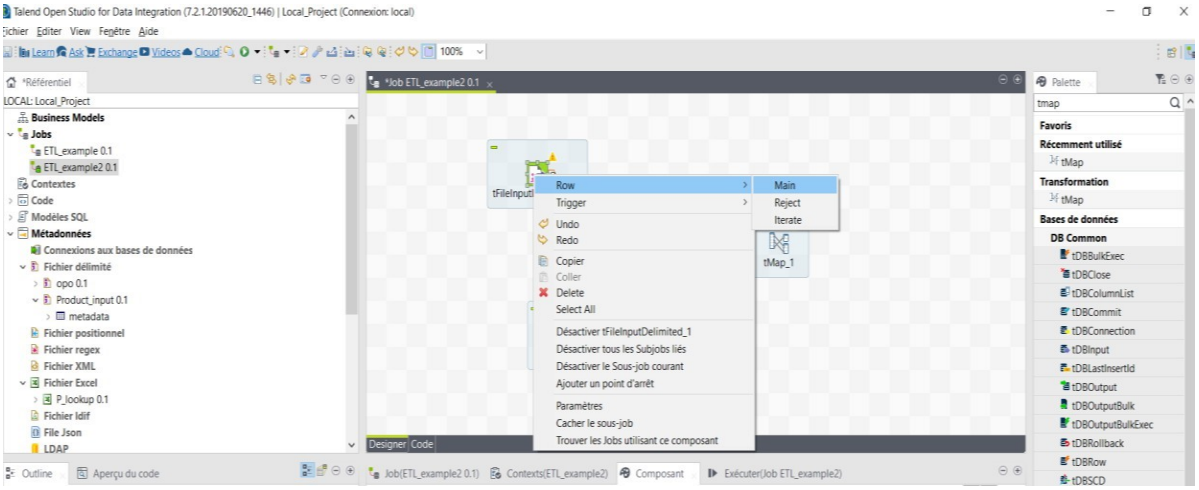

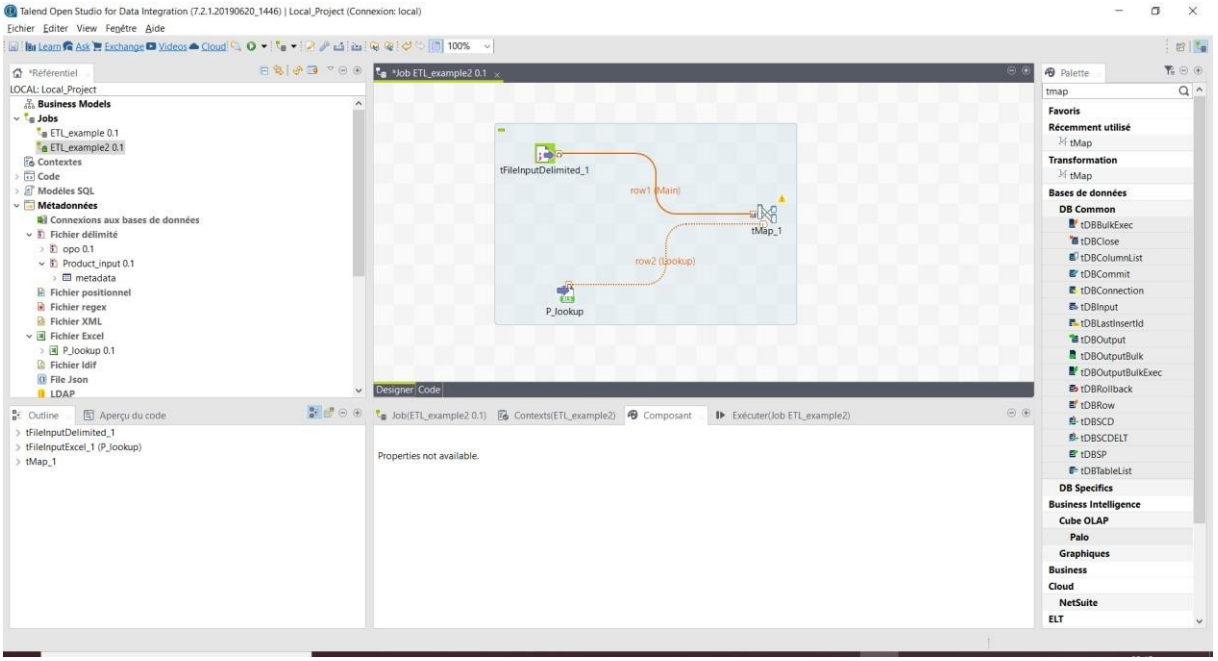

Une fois les deux fichiers connectés, cliquer sur **tmap**. La fenêtre suivante apparait :

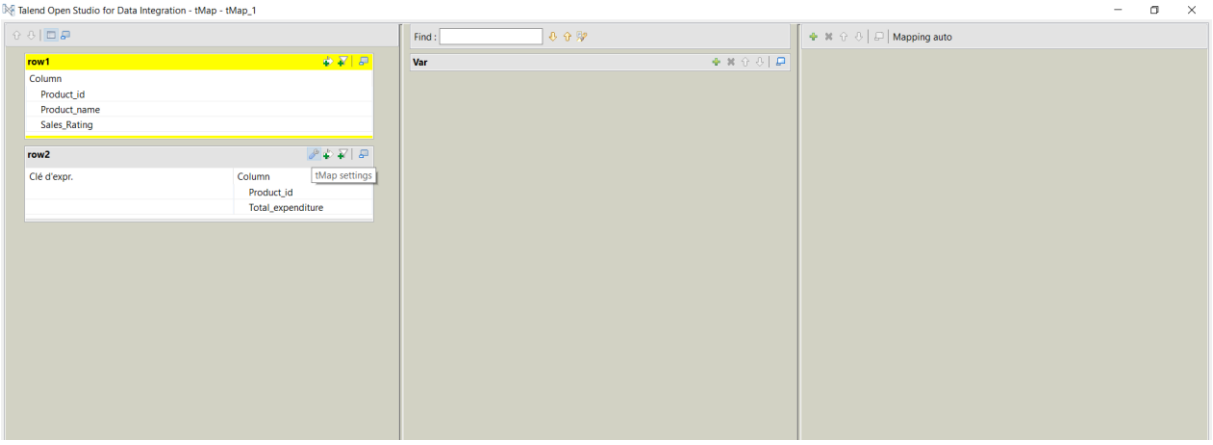

On clique sur l'icone et on clique sur Join model et on choisit **inner join** pour ne choisir que les produits ayant une correspondance dans la table P_lookup

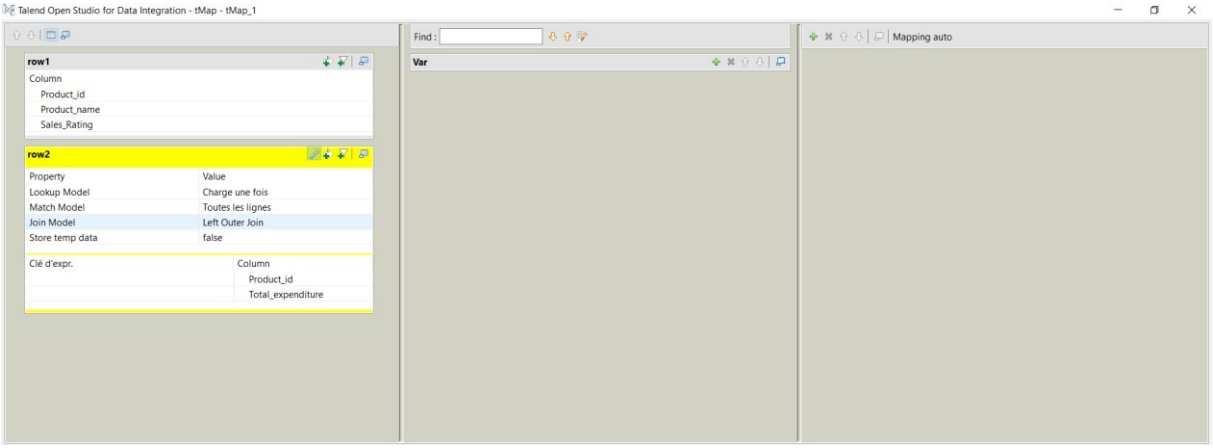

Faire descendre la clé Product_id de la premiére table à la deuxiéme table pour précise la clé de la jointure

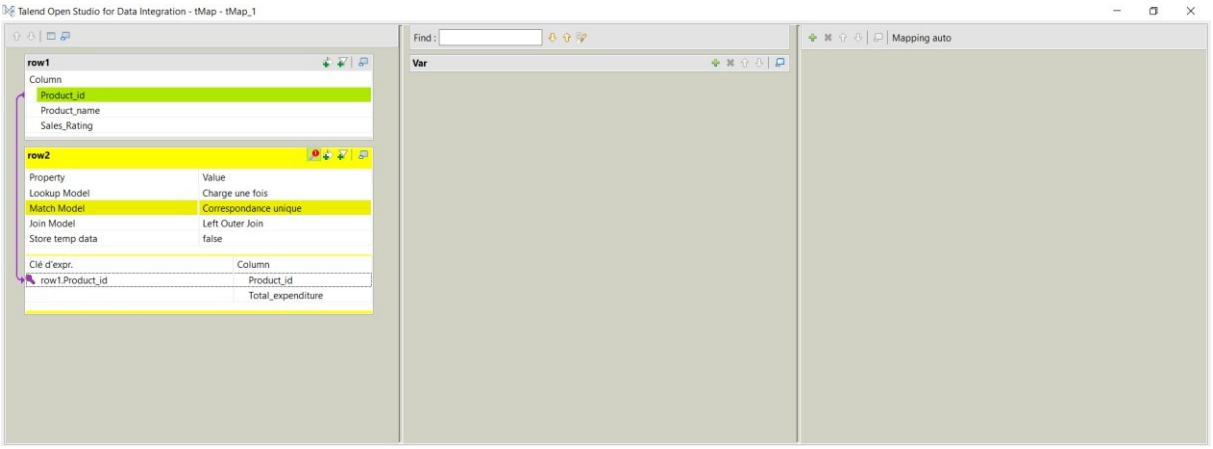

Appuyer sur le plus qui se trouve sur le coté droit de la fenetre, ajouter une sortie et nommer Product_out

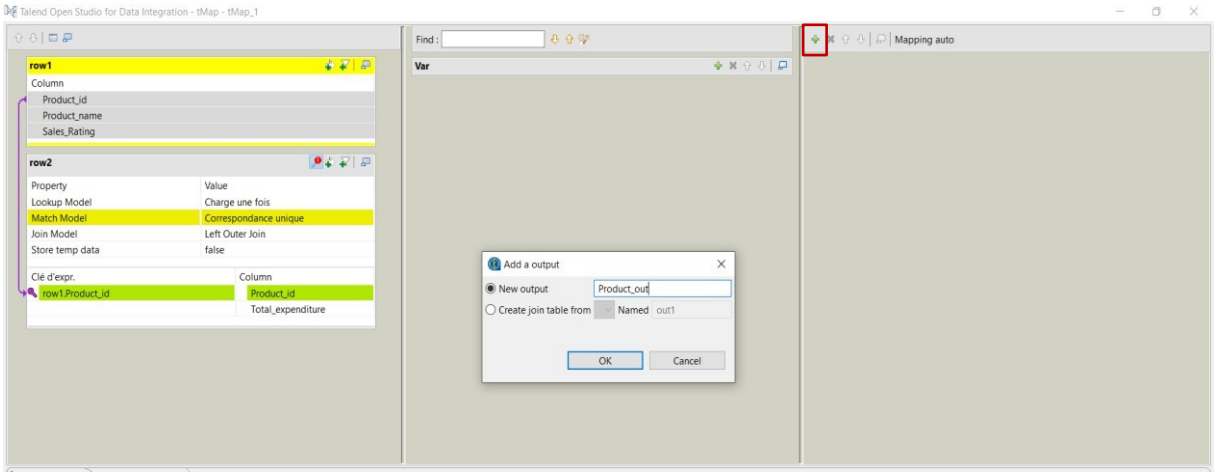

Glisser les champs à partir des deux tables et créer une deuxiéme table en sortie pour les produits qui n'ont pas de correcpondance dans la table P_lookup.

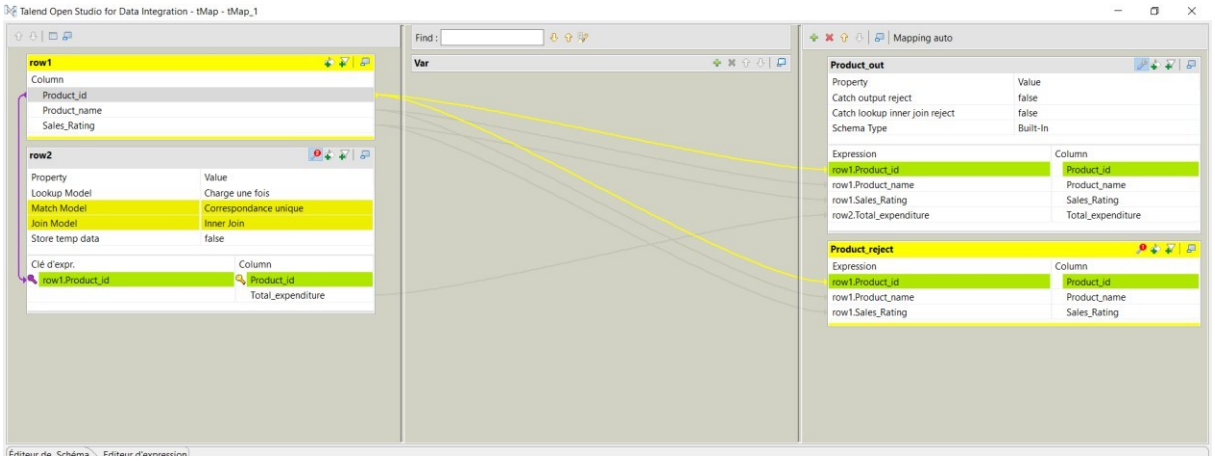

Appuyer sur dans la table Product_reject. Et changer la valeur **Cash inner join reject** de *false* a *true*.

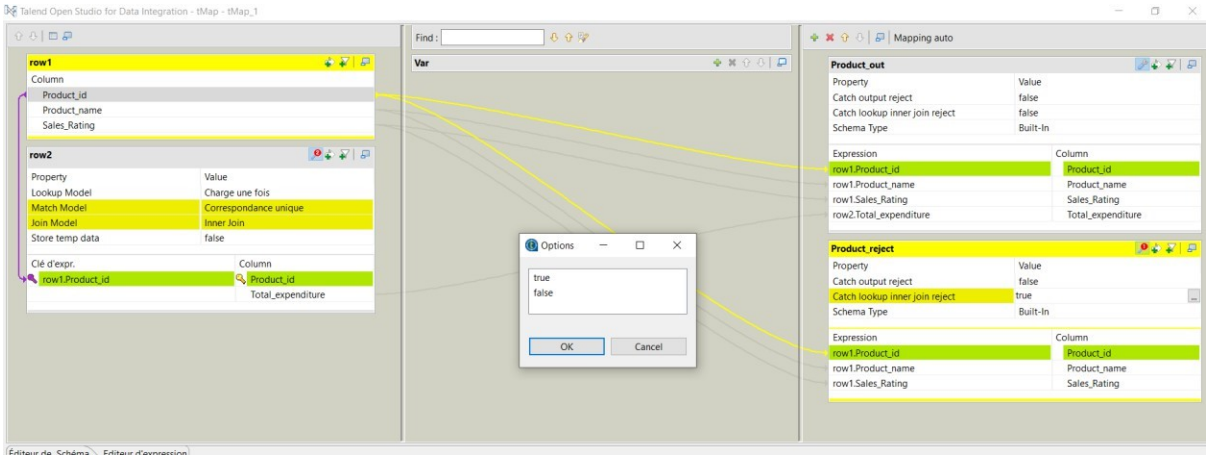

Insérer deux fichiers en sortie dans l'éditeur et les connecter à **tmap**

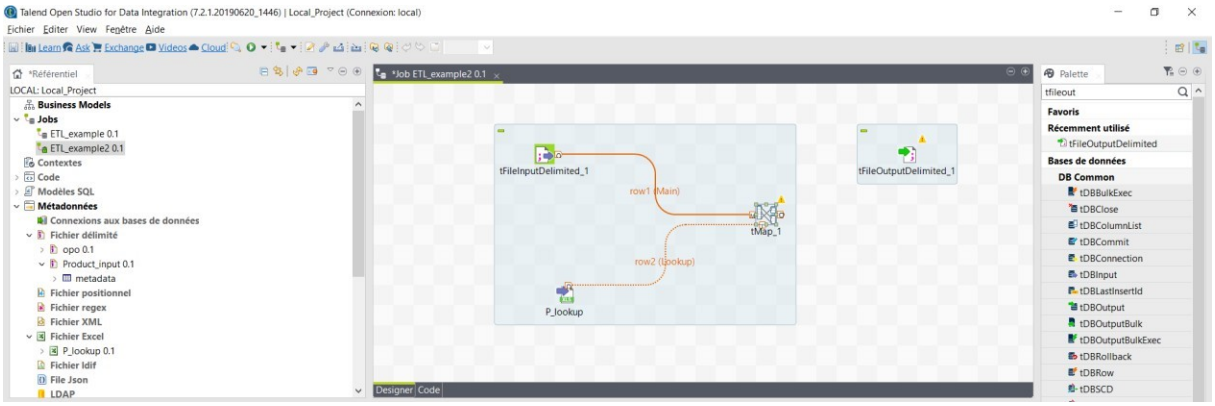

Un fichier recevra les données de Product_out et l'autre de Product_reject. Dans les paramétres de chaque fichier indiquer le chemin ou sera placé le fichier et cocher **Ecrire aprés**

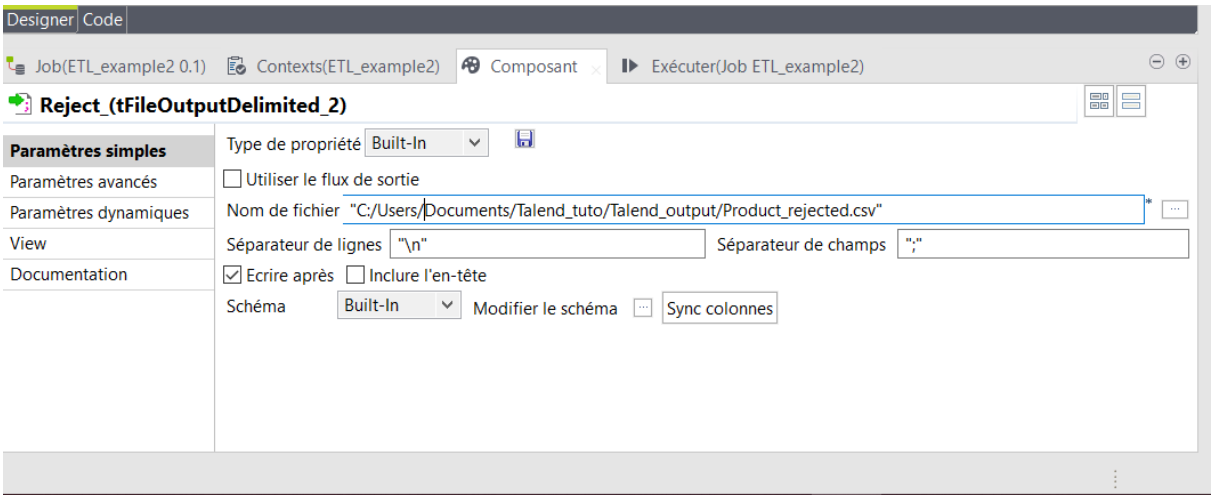

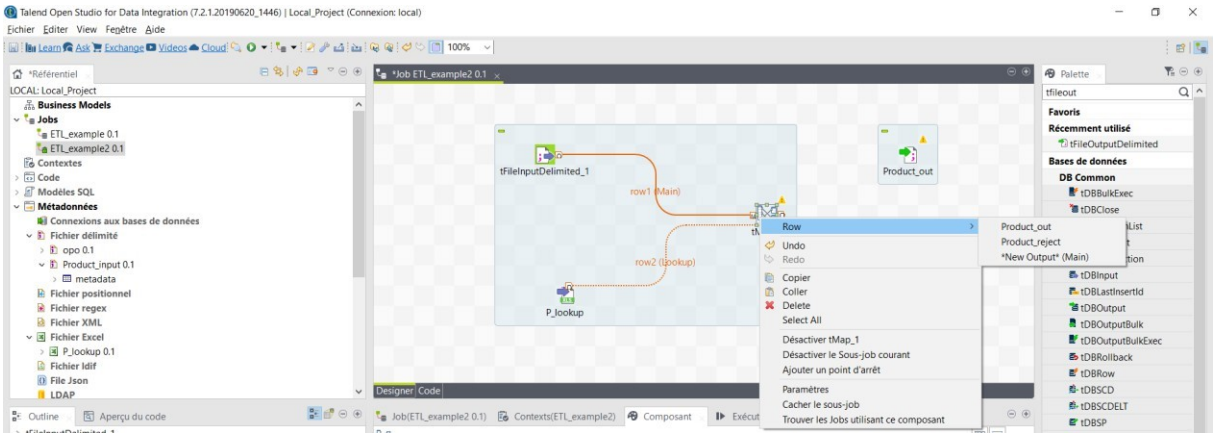

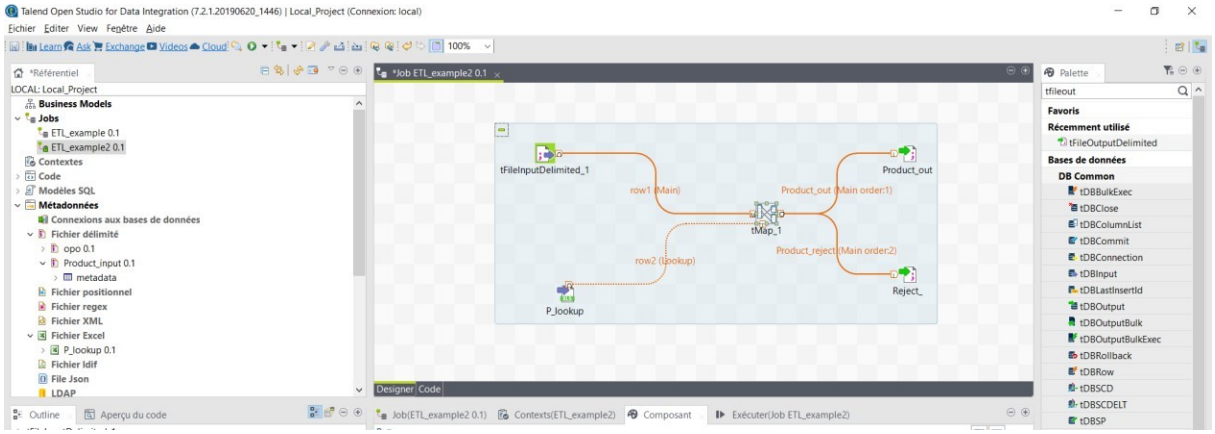

Ensuite exécuter le job

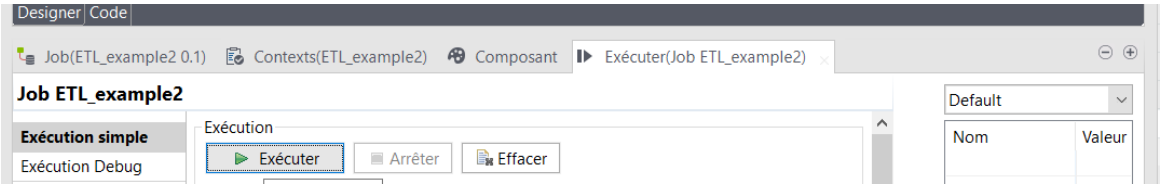

Remarquer que le fichier reject contient les lignes n'ayant pas de correspondance.

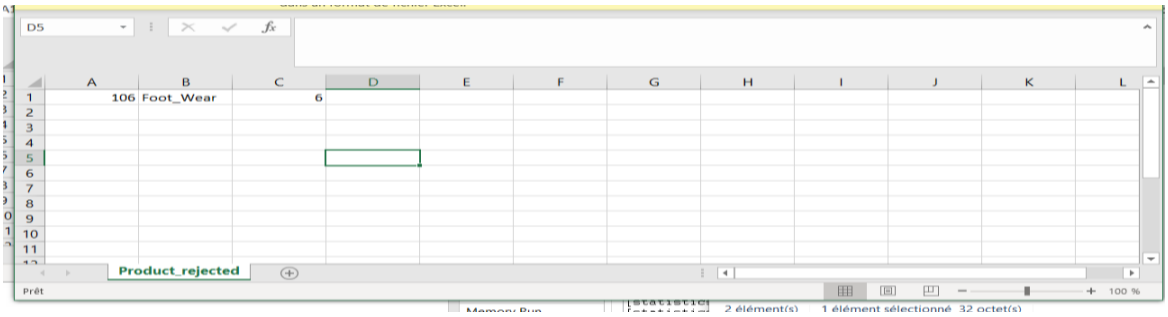

Et la table Product_out contient les lignes ayant une correspondance.

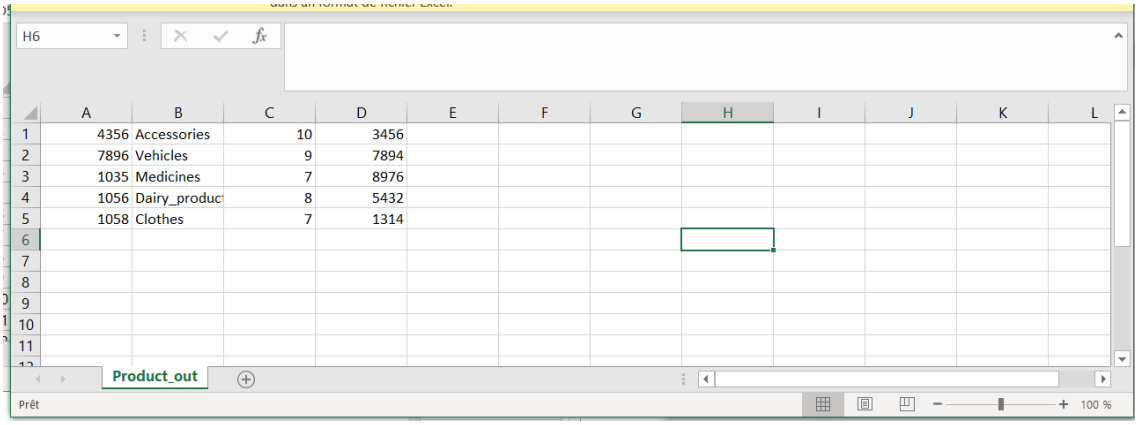

5- Opérations dur les champs

Pour remplacer le '_' par ' ' dans le champ Product_name, on clique sur tmap puis dans la table Product_out on clique sur ….

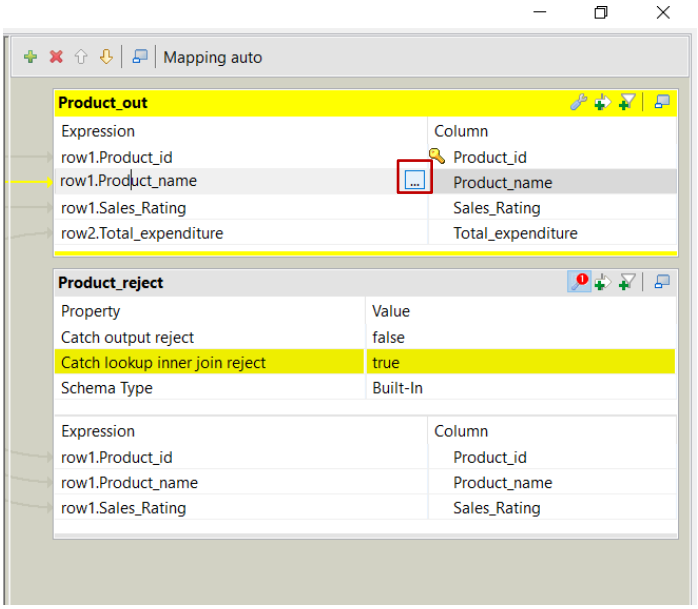

Ensuite le constructeur d'expression apparait, choisir **StringHandling** dans catégorie, EREPLACE dans fonctions et changer 'helloworld' par 'row1.Product_name' et remplacer '_' par ' '.

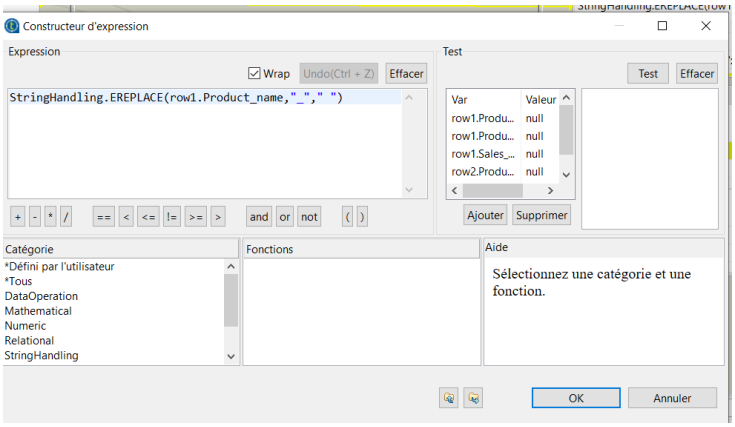

En sortie, on aura le résulat suivant :

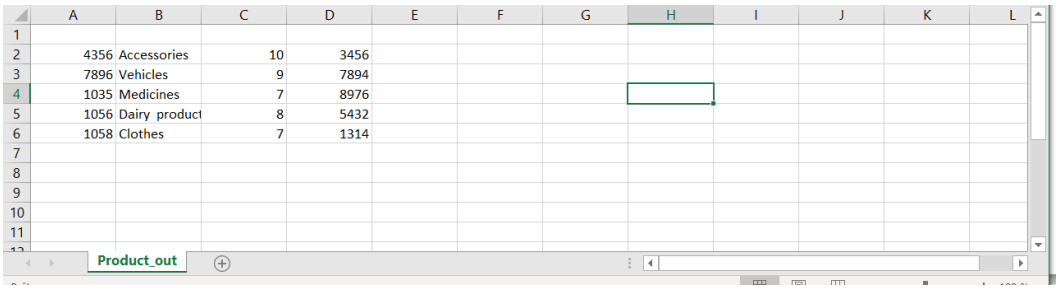

4356	Accessories	10	3456
7896	Vehicles	9	7894
1035	Medicines	7	8976
1056	Dairy product	8	5432
1058	Clothes	7	1314

Product_out

Pour filtrer les produits et ne garder que ceux ayant un classement supérieur à 7.

Pour cela ajouter une colonne en cliquant sur en bas de la fenêtre et la nommer **Category**

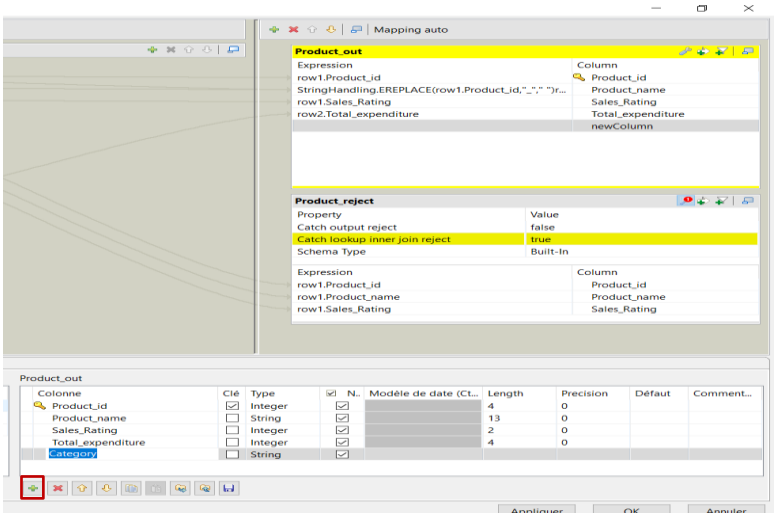

Cliquer sur les … de la colonne Category et ajouter la condition suivante

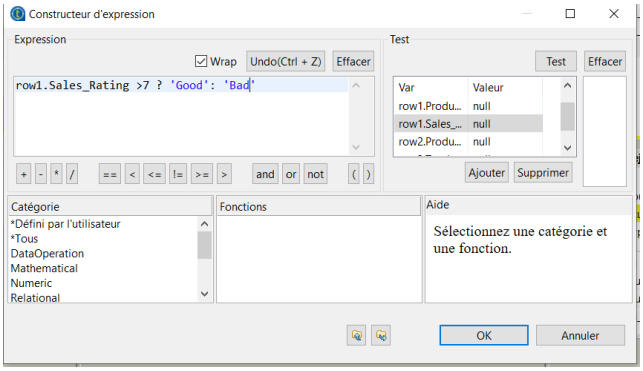

Propager les changements

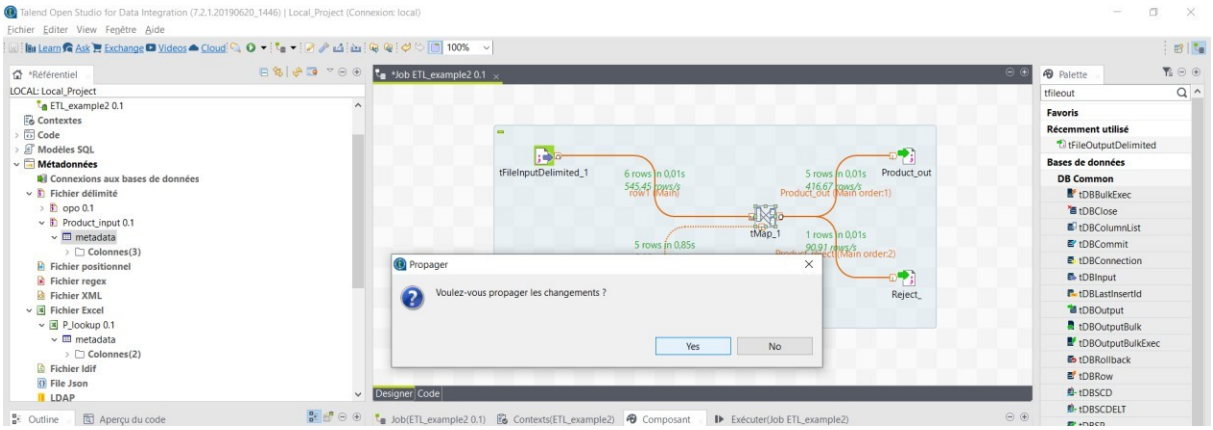

Ajouter le **tfilterRow** et préciser dans la colonne d'entrée **Category**, dans Opérateur vaut et dans Valeur 'Good'

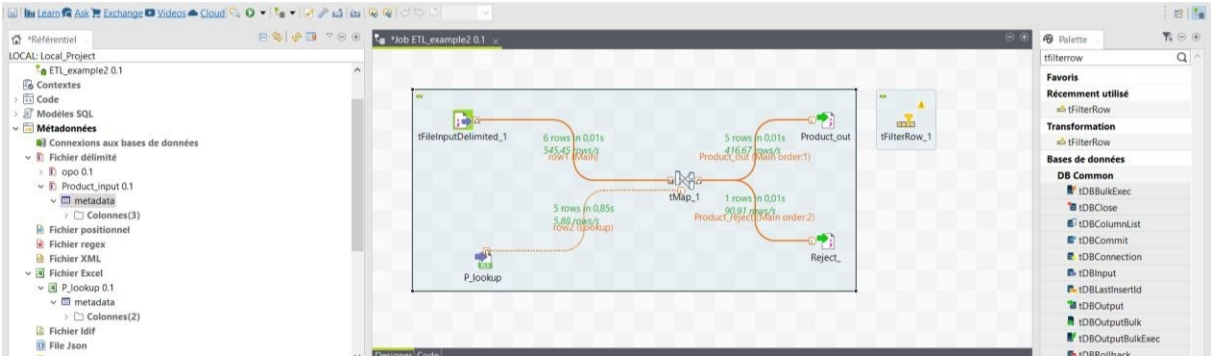

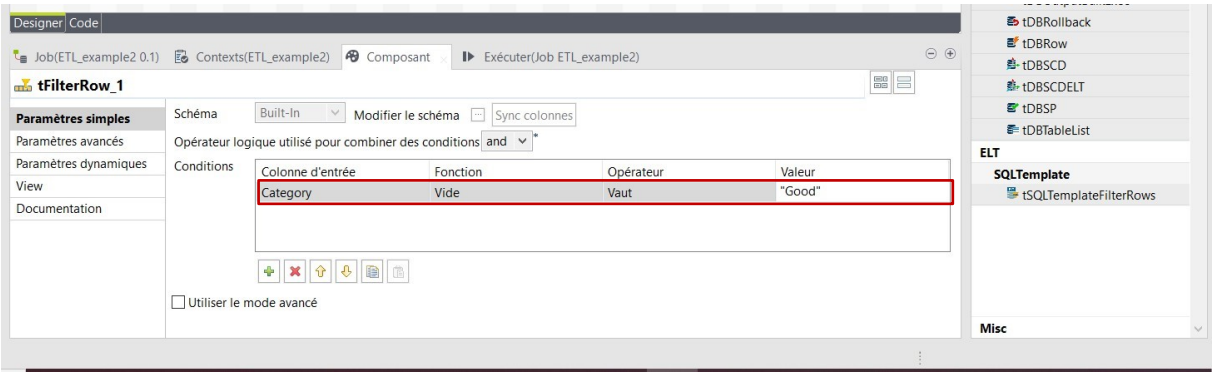

Connecter deux fichiers délimités en sortie (un pour les produits filtrés et l'autre pour les reject) et on précise leur chemins

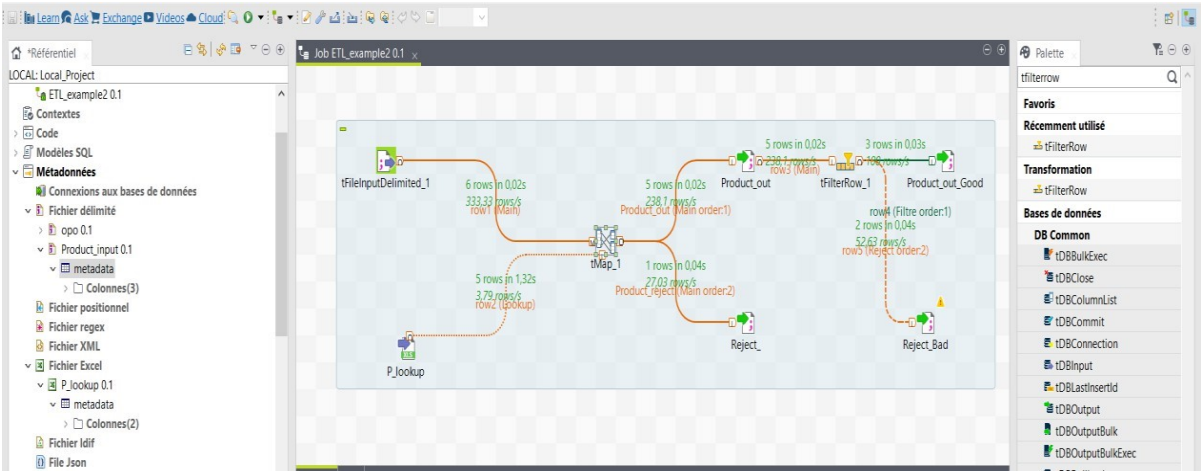

Exécuter le job et vérifier les résultats.

Les fichiers Product_out_Good et le fichier Reject_Bad sont comme suit :

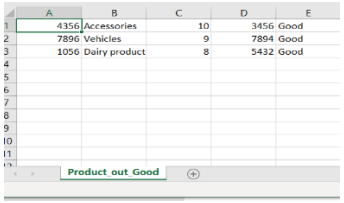

4356	Accessories	10	3456	Good
7896	Vehicles	9	7894	Good
1056	Dairy product	8	5432	Good

Product_out_Good

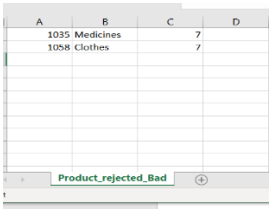

1035	Medicines	7
1058	Clothes	7

Product_rejected_Bad