

COMPTE RENDU

BI & Datawarehouse – Intégration de bases de données sur Talend Open
Studio

3e année Cybersécurité – École Supérieure d'Informatique et du
Numérique (ESIN)
Collège d'Ingénierie & d'Architecture (CIA)

Étudiant : HATHOUTI Mohammed Taha
Filière : Cybersécurité
Année : 2025/2026
Enseignants : M.RIADSOLH
Date : 6 avril 2026

Table des matières

1	Extraction des données à partir des sources de données	2
2	Chargement au niveau de la table Ventes	3
2.1	Configuration du tDBObject	3
2.2	Schéma de la table Ventes	3
2.3	Vérification en base	4
3	Agrégation des données de la table Ventes	5
3.1	Architecture du pipeline d'agrégation	5
3.2	tAggregateRow_1	5
3.3	tSortRow_1	5
3.4	Résultats affichés en console	5
4	Conclusion	6

1 Extraction des données à partir des sources de données

Les données sont extraites depuis la base Miniature2026 via quatre composants `tDBInput`. La connexion MySQL est configurée dans les Métadonnées de Talend avec les paramètres suivants : hôte `localhost`, port `3306`, base `Miniature2026`, utilisateur `talend`.

- **orders** : flux principal (*Main*) vers le `tMap`. Contient `orderNumber`, `orderDate`, `customerNumber`, etc.
- **products** : flux *Lookup*, jointé sur `orderdetails.productCode`.
- **orderdetails** : flux *Lookup*, jointé sur `orders.orderNumber`.
- **customers** : flux *Lookup*, jointé sur `orders.customerNumber`.




FIGURE 1 – Configuration du `tMap_1` : sources, clés de jointure et mappings

Le mapping de la sortie `vente` est le suivant :

Expression	Colonne de sortie
<code>orders.customerNumber</code>	<code>customerNumber</code>
<code>products.productCode</code>	<code>productCode</code>
<code>orderdetails.quantityOrdered</code>	<code>quantityOrdered</code>
<code>orders.orderDate</code>	<code>orderDate</code>
<code>products.buyPrice.multiply(new BigDecimal(orderdetails.quantityOrdered))</code>	<code>2*Amount</code>
<code>TalendDate.getPartOfDate("MONTH", orders.orderDate) + 1</code>	<code>2*orders_month</code>
<code>orders.orderNumber</code>	<code>orderNumber</code>

Remarque : `getPartOfDate("MONTH", ...)` commence à 0 (janvier), le `+1` corrige ce décalage.

2 Chargement au niveau de la table Ventes

2.1 Configuration du tDBOutput

Le composant tDBOutput_1 charge les données transformées directement dans la table Ventes de Miniature2026. Il est paramétré avec :

- **Type de propriété** : Référentiel (connexion Bases de données (MYSQL):Miniature)
- **Action sur la table** : Supprimer la table si elle existe et la recréer
- **Action sur les données** : Insert




FIGURE 2 – Paramètres de connexion du composant tDBOutput_1

2.2 Schéma de la table Ventes




FIGURE 3 – Schéma de mapping entrée/sortie du tDBOutput_1

Colonne	Type Talend	Type MySQL
customerNumber	int	INT
productCode	String	VARCHAR(15)
quantityOrdered	int	INT
orderDate	Date	DATE
Amount	BigDecimal	DECIMAL
orders_month	Integer	INT
orderNumber	int	INT

2.3 Vérification en base

Après exécution du job, la table **Ventes** est peuplée. La requête de vérification suivante confirme le résultat :

```
1 USE Miniature2026;
2 SELECT * FROM Ventes;
```

```
mysql> USE Miniature2026
Database changed
mysql> SELECT * FROM Ventes;
+-----+-----+-----+-----+-----+
| customerNumber | productCode | quantityOrdered | orderDate | Amount |
| orders_month | orderNumber |
+-----+-----+-----+-----+-----+
|          103 | S10_2016    |          39 | 2004-09-27 | 2691 |
|           9 |      10298 |
|          103 | S18_1589    |          26 | 2003-05-20 | 1715 |
|           5 |      10123 |
|          103 | S18_2625    |          32 | 2004-09-27 |  775 |
|           9 |      10298 |
|          103 | S18_2870    |          46 | 2003-05-20 | 2611 |
|           5 |      10123 |
|          103 | S18_3685    |          34 | 2003-05-20 | 2113 |
|           5 |      10123 |
|          103 | S24_1628    |          50 | 2003-05-20 | 1459 |
|           5 |      10123 |
|          ... | ...         |          ... | ...         | ... |
|          ... | ...         |
|          496 | S700_3505    |          35 | 2004-12-16 | 1788 |
|          12 |      10360 |
|          496 | S700_3962    |          31 | 2004-12-16 | 1663 |
|          12 |      10360 |
|          496 | S72_3212    |          31 | 2004-12-16 | 1032 |
|          12 |      10360 |
+-----+-----+-----+-----+-----+
2996 rows in set (0,01 sec)
```

3 Agrégation des données de la table Ventes

3.1 Architecture du pipeline d'agrégation

Après le chargement en base, les données sont agrégées et triées via le pipeline suivant, branché en aval de `tDBOutput_1` :

$$tDBOutput_1 \xrightarrow{\text{row1}} tAggregateRow_1 \xrightarrow{\text{row2}} tSortRow_1 \xrightarrow{\text{row3}} tLogRow_1$$




FIGURE 4 – Vue complète du Job tp44 avec pipeline d'agrégation

3.2 `tAggregateRow_1`

Le composant `tAggregateRow_1` calcule la somme des montants (`SUM(Amount)`) groupée par mois (`orders_month`) et par produit (`productCode`).

3.3 `tSortRow_1`

Le composant `tSortRow_1` trie les résultats par ordre croissant sur `orders_month`, afin d'obtenir un affichage mensuel ordonné de janvier à décembre.

3.4 Résultats affichés en console

Les résultats triés sont affichés par `tLogRow_1`. Le job s'est terminé avec le code de sortie 0.




FIGURE 5 – Extrait de la console d’exécution – triplets affichés par tLogRow_1

```
Starting job tp44 at 21:59 06/04/2026.
[statistics] connecting to socket on port 3926
[statistics] connected
350|1|1
334|1|15
121|1|16
...
496|12|18
447|12|9
282|12|14
[statistics] disconnected
Job tp44 ended at 21:59 06/04/2026. [exit code = 0]
```

4 Conclusion

Ce TP a permis de mettre en œuvre un pipeline ETL complet sous Talend Open Studio, en utilisant MySQL comme source et destination de données. Les étapes couvertes sont :

- **Extraction** : lecture de quatre tables MySQL (`orders`, `products`, `orderdetails`, `customers`) via des composants `tDBInput`, avec récupération des schémas depuis les Métadonnées Talend.
- **Transformation** : jointures multi-sources dans le `tMap`, calcul de colonnes dérivées (`Amount` via `BigDecimal.multiply`, `orders_month` via `TalendDate.getPartOfDate`), et gestion des rejets de jointure vers un fichier CSV.
- **Chargement** : insertion dans la table `Ventes` via `tDBOutput` avec recréation automatique de la table. La table est correctement peuplée avec 2 996 lignes, vérifiée par requête SQL directe.
- **Agrégation** : utilisation de `tAggregateRow`, `tSortRow` et `tLogRow` pour consolider les ventes mensuelles par produit et les visualiser triées par ordre croissant de mois.